

التسويق الذكي واستهداف المستخدمين في الإعلان عبر الانترنت باستخدام التنقيب في البيانات

Intelligent marketing and targeting users in advertisement online using data mining



أعدت هذه الأطروحة لنيل درجة ماجستير الدراسات العليا في علوم الويب

اعداد الطالب:

أسامة كيالي

اشراف الدكتور

سعيد أبو طراب

2	الفصل 1 الاطار العام للدراسة:
2	1.1 مقدمة:
2	1.2 مبررات البحث:
2	1.3 مشكلة البحث:
3	1.4 الهدف من هذه الدراسة:
3	1.4.1 الهدف البحثي:
3	1.4.2 الأهداف المرحلية:
3	1.5 تنظيم الاطروحة:
3	1.6 الخاتمة:
5	الفصل 2 الدراسة المرجعية:
5	2.1 مقدمة:
5	2.2 أنواع الإعلانات والمنصات المستخدمة في الإعلان:
5	2.2.1 منصات إعلانية:
6	2.2.2 أنواع الإعلانات:
8	2.2.3 انشاء الإعلانات للشركة:
9	2.3 الذكاء الاصطناعي و التعلم الآلي و التعلم العميق:
9	2.3.1 intelligence Artificial:
9	2.3.2 machine learning:
14	2.3.3 Deep Learning:
15	2.4 الدراسة البحثية (الدراسات السابقة):
17	2.5 الخاتمة:
20	الفصل 3 الدراسة التجريبية ومناقشة النتائج:
20	3.1 مقدمة:
20	3.2 دراسة مراحل التنبؤ بإمكانية استجابة المستخدم:
20	3.2.1 مرحلة الحصول على قاعدة البيانات وخواصها(Data):
22	3.2.2 مرحلة انشاء وتدريب نماذج التعلم الآلي والتعلم العميق (learning):
27	3.2.3 الخطوات ضمن هذه المرحلة:
27	3.3 مرحلة عرض الإعلانات:
27	3.3.1 الخطوات ضمن هذه المرحلة:
28	3.4 تقارير عن الأداء والنتائج:
28	3.5 عرض بنية النموذج المقترح والمعلّمت:
29	3.6 النموذج البياني التفصيلي لدقة النموذج المقترح:
29	3.7 الخاتمة:
31	الفصل 4 الآفاق المستقبلية والتحديات التي واجهتنا والخلاصة:

31	4.1 مقدمة:
31	4.2 التحديات التي واجهتنا
31	4.2.1 قابلية التوسع Scalability:
31	4.2.2 تباين البيانات Data sparsity:
31	4.2.3 البداية الباردة Cold start:
31	4.2.4 ملكية البيانات:
31	4.2.5 خصوصية البيانات:
32	4.2.6 التحليل غير التقليدي:
32	4.2.7 فيروس الكورونا COVID-19:
32	4.3 الآفاق المستقبلية:
32	4.4 الخاتمة:
33	4.5 المراجع:

فهرس الاشكال

6	Banner1 Figure
6	Pop-up2 Figure
7	Interstitials3 Figure
7	Video ads4 Figure
9	deep learning5 Figure
9	Cluster6 Figure
10	K-Means7 Figure
10	Classification8 Figure
11	LR9 Figure
11	LOG R10 Figure
12	NB11 Figure
12	SVM12 Figure
13	Decision Tree13 Figure
13	ANN14 Figure
14	قياس الدقة 15 Figure
14	DNN16 Figure
20	Workflow diagram 17 Figure
22	GeographyKey18 Figure
22	ProductSubcategoryKey19 Figure
22	ProductKey20 Figure
22	CustomerKey21 Figure
22	NumberCarsOwned22 Figure
22	YearlyIncome23 Figure
22	TotalChildren24 Figure
22	HouseOwnerFlag25 Figure
22	Age26 Figure
22	Gender27 Figure
22	NumberChildrenAtHome28 Figure
22	OrderNumber29 Figure

22.....	MaritalStatus30 Figure
23.....	create model32 Figure
23.....	DSV34 Figure
23.....	mining model31 Figure
23.....	classification Matrix 33 Figure
25.....	train_test_split35 Figure
25.....	values data36 Figure
25.....	Deep Neural Network37 Figure
26.....	model 38 Figure
26.....	model compile39 Figure
26.....	save best result40 Figure
26.....	train41 Figure
27.....	model summary42 Figure
27.....	Save model43 Figure
28.....	results44 Figure
29.....	accuracy46 Figure
29.....	loss46 Figure

فهرس الجداول

8.....	1أنواع الاعلانات Table
16.....	2جدول مقارنة خوارزميات Table
20.....	Table 3 Data AdventureWorksDW2019
22.....	4 احصائيات Table
23.....	basic measures 5 Table
24.....	machine learning الألي تحليل النتائج Table 6
28.....	Table 7full results
28.....	البنية النهائية والمعلومات Table 8

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

وَقُلْ رَبِّ زِدْنِي عِلْمًا

لَا إِلَهَ إِلَّا اللَّهُ مُحَمَّدٌ عَبْدُهُ وَرَسُولُهُ

اهداء

إلى الذي أضيء عمره يحترق كالشمعة لكي أبصر النور
إلى الذي عمل جاهدا لإدخال السعادة إلى قلوبنا
إلى الذي رغم كل جراح العمر ومتاعبه ظلت التضحية عنواناً له
إلى أبي الحبيب.
إلى من سهرت الليل لأنام ... إلى أجمل من رأت عيني
إلى التي الجنة تمت أقدامها إليك أيها الملاك السماوي
إليك يا أمي العزيزة.
إلى من أشد بهم أزي أخوتي وأخواتي
إلى كل من له حق علي.

-الملخص:

في هذا العصر الرقمي التنافسي مع وجود ملايين الشركات القائمة على الخدمات في السوق، تحاول معظم الشركات جاهدة البقاء على قيد الحياة واكتساب ميزة تنافسية على الآخرين. تحتاج كل شركة إلى استراتيجية تسويق تمنحها ميزة على الشركات الأخرى في السوق. للحصول على هذه المزايا القوية يترتب على هذه الشركة القيام بإعلانات مميزة لكسب أكبر قدر ممكن من العملاء لديها، فمن الضروري لهذه الشركة عند تقديم إعلان ما عن منتج لها أن تفهم عملائها بالشكل التالي أولاً: فهم كيف يشعرون، ويفكرون، ويعقلون، ويختارون بين المنتجات المختلفة المتاحة أمامهم. وذلك من خلال فهم عملائها وكيفية سلوكهم الشرائي بشكل أفضل، يمكن للشركة زيادة الإعلانات، وتحسين تجارب المستخدم، والتنبؤ بكيفية استجابة العملاء لاستراتيجياتها التسويقية، والاحتفاظ بالعملاء المخلصين، وكسب عملاء جدد من خلال إعلانها المميز لديها. الغرض من هذا المشروع البحثي هو التحقيق في سلوك شراء المنتج من قبل عملاء الشركة لتمكينها من أن تصبح واحدة من أفضل الشركات التجارية من حيث توفيرها للمنتج المفضل لدى عملاء الشركة.

تم بناء نماذج باستخدام خوارزميات التعلم الآلي (Machine learning): Regression Logistic, Naïve Bayes, Decision Tree, Neighbor K-Nearest, Support Vector Machine, Random Forest، وخوارزميات التعلم العميق (Deep learning) للتنبؤ بمشتريات العملاء بعد عرض الإعلان للمنتج المتوفر وتم إجراء مقارنة بين هذه النماذج لاختيار أفضل نموذج حسب توقع سلوك العملاء في الشراء. تم استخدام Accuracy, Precision, Recall, F1-Score, MCC, ROC لتقييم أداء النموذج على عينة الاختبار. لعبت المتغيرات مثل العمر والراتب السنوي دوراً مهماً في التنبؤ إذا كان العميل سيشتري منتجاً أم لا في حالة رؤيته للإعلان.

ستمكن النماذج المطورة المدراء التنفيذيين في شركة من اتخاذ قرارات مستنيرة بشأن النمو المستقبلي للشركة. بشكل عام حل هذا المشروع ماذا وأين ومتى وكيف يشتري العملاء منتجات الشركة.

-Abstract:

In this competitive digital age with millions of service-based companies in the market, most companies are trying hard to survive and gain a competitive advantage over others. Every company needs a marketing strategy that gives it an advantage over other companies in the market. In order to have these powerful advantages, this company should offer premium ads to win as many customers as possible. It is necessary for this company when presenting an advertisement for a product to understand its customers in the following way first: understanding how they feel, think, use their minds, and choose among the different products available to them. throughout understanding its customers and their purchasing behavior well; thus a company can increase ads, improve customers experiences, predict how customers will respond to its marketing strategies, retain loyal customers, and gain new customers through its premium ads.

The purpose of this research project is to investigate the behavior of customers when purchasing the product to enable the producing company to become one of the best trading companies in terms of providing the preferred product to the company's customers.

Models are designed using machine learning algorithms (Machine learning): Logistic Regression, Support Vector Machine, K-Nearest Neighbor, Decision Tree, Naïve Bayes, Random Forest and deep learning algorithms (deep learning) for predicting Customer purchases after displaying the advertisement of the available product and comparing these models to choose the best model according to the expectations of customers' purchasing behavior. It was used Accuracy, Precision, Recall, F1-Score, MCC, ROC To evaluate the performance of the model on the test sample. Variables such as age and annual salary played an important role in predicting whether or not a customer would buy a product if they saw an advertisement. Enhanced samples will enable company executives to make decisions which were well studied concerning the company's future growth. In general, this project has defined what, where, when and how customers buy the company's products.

Keywords: Machine learning, Deep learning, Artificial intelligence.

شكر وعرفان

يسعدني أن أتقدم بعظيم الشكر ووافر الامتنان الى
المشرف الدكتور سعيد أبو طراب على ما قدمه لي من
نصح وارشاد وتوجيهات قيمة كانت لها كبير الأثر في
تصويب وتوجيه هذا البحث.

كما أتوجه بالشكر والتقدير الى السادة الأفاضل رئيس
وأعضاء لجنة الحكم والمناقشة لتفضلهم بقبول قراءة
هذا البحث والحكم عليه وأيضا أتوجه بالشكر والامتنان
الى رئيس الجامعة وأعضاء الهيئة التدريسية في قسم
ماجستير علوم الويب، والى كل من ساعدني في انجاز
الدراسة الميدانية.



الدراسات العامة للدراسة

الفصل 1 الإطار العام للدراسة:

1.1 مقدمة:

يوفر الإعلان عبر الإنترنت نشاطًا تجاريًا أرباحه بمليارات الدولارات تعود للشركة المنتجة لأنه تجربة تسويقية ناجحة عندما يصل المستخدمين إلى الخدمات عبر الإنترنت باستخدام الأجهزة الإلكترونية، مثل أجهزة الكمبيوتر المكتبية والأجهزة اللوحية والهواتف الذكية وما إلى ذلك. باستخدام الإنترنت كوسيلة للدعاية، تعمل الشركات بحرفية وكفاءة عالية لتوفير الإعلانات وتسليمها للمستخدمين من خلال العديد من المنصات، مثل محركات البحث والمواقع الإخبارية والشبكات الاجتماعية والمجلات المطبوعة والصحف حيث يتم تخصيص مساحات معينة لعرض الإعلانات والخدمات ومواقع الويب عبر الإنترنت بمكونات قابلة لعرض الرسائل التسويقية. فإن الإعلانات التي تُعرض للمستخدمين عن المنتج، فإما المنتج قد بيع مسبقًا بواسطة البائعين للمشتريين أو يتم تحديده ديناميكيًا من خلال التنبؤ به في الوقت الفعلي بعد معرفة المتغيرات (عمر وجنس وراتب السنوي وعدد الأولاد والمهنة والحالة الاجتماعية.....) الموجودة في بيانات المستخدم.

1.2 مبررات البحث:

لا توجد دراسة شاملة للإجابة على العديد من الأسئلة المهمة. ما نوع البيانات المتاحة للتنبؤ باستجابة المستخدم؟ كيف يمكن توقع استجابة المستخدم بطريقة موثوقة؟

حيث تحتاج الشركات إلى فهم عملائها قبل تطوير استراتيجيات التسويق لاكتساب ميزة تنافسية على الآخرين. فمن المهم فهم العملاء والعوامل التي تحفزهم على إجراء عمليات الشراء، ولاستهداف المستخدمين المحتملين والاحتفاظ بالعملاء الحاليين، ومن الضروري فهم كيفية تفكير العميل، وسبب استجابته، واتخاذ قرارات الشراء عند اختيار منتج من مجموعة واسعة من البدائل المتاحة في الأسواق.

ومن وجهة نظر تجارية فإن المراحل الأولى للإعلانات عبر الإنترنت تنبئ بمستقبل مزدهر، ولذلك فإن المعلنين اعتبروا أن شبكة الإنترنت وسيلة اتصال جيدة تتميز بالسهولة والسرعة بالوصول إلى الجمهور المستهدف حيث إن الإعلانات متوفرة خلال 24 ساعة و365 يوم في السنة وبأقل كلفة مقارنة بوسائل الاتصال التقليدية

1.3 مشكلة البحث:

في كثير من الأحيان عندما يتم التسويق لمنتج معين يتم بطريقة غير فعالة أو غير موجهة بمعنى أن تقوم المؤسسة بإرسال إعلاناتها لكل المستخدمين بصرف النظر عن مدى أهمية الإعلان لكل مستخدم على حده. وهذا يؤدي إلى هدر موارد الجهة المُعلنة ووقتها وجهدها في أماكن غير مناسبة وكذلك يؤدي إلى ضياع زمن المستخدم باطلاعه على إعلانات غير مفيدة له

1.4 الهدف من هذه الدراسة:

1.4.1 الهدف البحثي:

بناء نموذج يعتمد على تطبيق خوارزميات التعلم العميق لتحسين دقة التنبؤ باحتياجات مستخدم ما لتوجيه الإعلان المناسب له حسب احتياجاته.

1.4.2 الأهداف المرحلية:

- بناء نموذج البيانات
- اختيار ال dataset
- اختيار الخوارزميات التعلم العميق والتعلم الآلي
- الدراسة المرجعية لنماذج شبيهة
- تحديد معايير التقييم
- مناقشة النتائج

1.5 تنظيم الأطروحة:

نُظِّم هذا العمل على عدة فصول وهي:

- الفصل الأول: يحتوي هذا الفصل على مدخل الى البحث يتضمن مقدمة و مبررات البحث والهدف البحثي ومشكلة البحث.
- الفصل الثاني: يحتوي هذا الفصل على دراسة نظرية نبين فيها أهم أنواع الإعلانات والمنصات المستخدمة في الإعلان وتأثيرها على المستخدم و نبين أيضاً الخوارزميات التقليدية والحديثة في مجال التنبؤ.
- الفصل الثالث: يحتوي هذا الفصل على دراسة مرجعية لنبين فيها أهم الأبحاث في هذا المجال و يحتوي هذا الفصل على المنهجية البحثية حيث يتم شرح بالتفصيل عن خطوات العمل التي قمنا بها من الحصول على البيانات وتنظيفها وتطبيق خوارزميات التصنيف وعوامل التقييم والأدوات المستخدمة، اهم النتائج وتقييمها ومناقشتها وعرض التقارير عن الأداء.
- الفصل الرابع: يحتوي هذا الفصل على شرح أهم التحديات التي واجهتنا والأفاق المستقبلية للبحث والخاتمة.

1.6 الخاتمة:

في هذا الفصل تم تحديد هدف البحث والغاية منه، لبناء نموذج يعتمد على تطبيق خوارزميات التعلم العميق ليتم التنبؤ باحتياجات المستخدم ليتم بعدها عرض الإعلان المناسب لاحتياجاته، وعرض احصائيات عن الإعلانات والتسويق.



الدراسة المرجعية

الفصل 2 الدراسة المرجعية:

2.1 مقدمة:

شهد الإعلان عبر الإنترنت تطوراً مستمراً في العقدين الماضيين. بدءاً من اللافتات الثابتة على مواقع الويب، ونهاية الى ما توصل اليه التطور الآن. حيث يتم تقديم الإعلانات بناءً على أنواع الاعلانات ومنصاتها[1]. كما أن الاهتمام الزائد بوسائل الإعلان أدى بالمعلنين أن يتعمقوا أكثر فيها حيث انهم لجئوا لدراسة جوانب أخرى في تطوير عملية الإعلان باللجوء الى فكرة التنبؤ بردود أفعال وسلوكيات المستخدمين فبنوا اعلاناتهم على نتائج التنبؤ فكانت هذه النتائج أفضل بكثير. وسنتحدث عن في هذا القسم عن أنواع الإعلانات والمنصات المستخدمة في الإعلان ودراسة آخر ما توصل اليه العلم في مجال الذكاء الاصطناعي والتعلم الآلي والتعلم العميق للتنبؤ بحاجات المستخدمين وما سيشترون.

2.2 أنواع الإعلانات والمنصات المستخدمة في الإعلان:

ففي هذا القسم، نلخص بإيجاز أنواع المنصات الاعلانية وأنواع الإعلانات

2.2.1 منصات إعلانية:

هناك العديد من المنصات الاعلانية التي تم اقتراحها لخدمة الإعلانات للمستخدمين، اعتماداً على استجابة العملاء الذين يصلون إلى الشبكة. منها:

A. التسويق على شبكة البحث الاعلانية:

البحث عن الإعلانات هو نظام إعلانات يستند إلى محرك البحث ويستخدم استعلام العميل وكما يتم من خلاله عرض قائمة بالإعلانات المتعلقة باستعلامات العملاء.

B. الإعلانات المصورة:

يُعد الإعلان على الشبكة الاعلانية أحد أحدث أشكال الإعلان عبر الإنترنت الذي يعمل على أساس المزايدة في الوقت الفعلي لاختيار وعرض الإعلانات المخصصة في المناطق المخصصة لصفحات الويب. يختلف سياق الإعلان المصور عن الإعلانات على شبكة البحث حيث توفر استعلامات العميل سياقاً واضحاً لتفضيلات العميل، وغالباً ما يقتصر على الصفحات التي يزورها العملاء / يطلبونها.

C. إعلانات وسائل التواصل الاجتماعي:

أصبحت شبكات التواصل الاجتماعي عناصر مشتركة في الحياة اليومية، وتوفر فرصة للعملاء للتفاعل وتبادل المعلومات. وتحفز شعبية هذه المنصات الشركات على استهداف عملائها المحتملين. تحقيقاً لهذه الغاية، يهدف المعلنون

إلى تقديم منشورات أو تغريدات مخصصة في منصات التواصل الاجتماعي، مثل Twitter و Facebook و Instagram، لجذب العملاء.

2.2.2 أنواع الإعلانات:

من أجل الترويج للمنتجات والخدمات في الإعلان عبر الإنترنت، تم تصميم أنواع مختلفة من الإعلانات كوسيلة للإعلان، منها:

A. إعلانات Banner:

إن إعلان Banner كان موجود منذ بداية الإعلان عبر الإنترنت في التسعينيات، وهو من أنواع الوسائط القياسية الرئيسية للإعلان في الإنترنت. يتم تنظيمه بواسطة مقتطفات نصية أو صورية أو محتويات متحركة موضوعة في منطقة معينة من صفحات الويب، يقدم إعلان Banner رسالة المعلنين إلى العملاء لجذب انتباههم حول المحتوى الذي يتم الترويج له كما في الشكل Figure 1. وقد أثبتت عدد من نتائج الدراسات المتنوعة أهمية أشكال وأنماط إعلانات Banner في نموذج معالجة الإعلانات التفاعلي حيث وصلت إلى:

- هذه الإعلانات تزيد وعي زوار الموقع للمنتجات المعلن عنها حتى بدون الضغط على Banner.
- عندما يضغط زوار الموقع على هذه الإعلانات (Banner) فإنها تؤثر على اتجاهاتهم ومن ثم على نية شرائهم، وتكون ذات فعالية أكثر من حالة عدم الضغط على إعلان Banner
- حجم إعلانات Banner له أثر وفروقات في معالجة المعلومات حيث أن إعلانات Banner الكبيرة على الغالب يكون تأثيرها على العميل أكبر من تأثير الإعلانات الصغيرة.

B. إعلانات Pop-up:

يطلق عليها "Pop-up advertisements" وهي اختصاراً لتقنية إعلانية عبر الإنترنت (تظهر أو تقفز) فجأة لزائر الموقع خارج إطار الموقع الذي يزوره، حيث تظهر ضمن إطار منفصل يفتح تلقائياً حالما يزور العميل بعض المواقع الخاصة. حيث تتصف إعلانات Pop-up بأنها إعلانات مزعجة تطفلية تقاطع عمل الزائر وتطره لإغلاقها من أجل متابعة عمله كما في الشكل Figure 2 وهنا يجب على المستخدم أن يضغط على الإعلان أو على مكان خارج إطار إعلان Pop-up بغية الرجوع إلى إطار صفحة الويب التي يزورها [2] حيث أن ظهورها يقاطع إبحار مستخدمي الإنترنت في صفحات الويب [3] تهدف إعلانات Pop-up إلى جذب ولفت انتباه وتركيز العملاء نحو هذه الإعلانات، حيث تقفز وتظهر هذه الإعلانات بدون أي تنبيه ويطلق عليها اسم "Pop up Blindness" (الإعلانات العمياء).




Figure 1 Banner





Figure 2 Pop-up

C. الإعلانات البينية:

يشبه هذا النوع من الإعلانات الفواصل الاعلانية التي تظهر بين برنامج وآخر عبر الشاشة. وتتشابه هذه الإعلانات



Interstitials 3 Figure

مع Pop-up إلا أن الفرق بينهما أن الإعلانات Interstitials لا تقاطع تفاعل العميل مع الإنترنت حيث أنها تظهر بينما العميل ينتظر تحميل الصفحة التالية إلا أنها تتصف بتحكمية أقل حيث لا يوجد خيار للعميل لكي يخرج من الصفحة أو ليقف هذا الإعلان أو حذفه وبهذا يكون المستخدم أضاع وقته في مشاهدة إعلانات عن منتجات ليست ضمن اهتماماته. كما في الشكل 3 Figure

D. الإعلانات النصية:

هي أكثر أنواع الإعلانات شهرة في العديد من المنصات الإعلانية مثل إعلانات البحث المدعومة أو تسويق الرسائل القصيرة (SMS) أو الإعلان عبر البريد الإلكتروني [4].

E. إعلانات مواقع التواصل الاجتماعي (Social Web Advertising):

إن كلمة وسائل التواصل الاجتماعية ليست فقط كلمة مشهورة تتداول بين الأفراد، بل إنها طريقة للعيش والتأقلم مع أنماط حياة جديدة وقد جلب الانتشار السريع لهذه الوسائل معه ديناميكية حياة اجتماعية جديدة ومجتمع مدني أكثر شمولية، وفرصاً وثروة حقيقية لرجال الأعمال والشركات وتتجلى أهمية التسويق عبر القنوات الاجتماعية في كونها تمكن الأفراد والشركات من الترويج عن منتجاتهم أو أفكارهم، بالإضافة إلى تواصلهم مع مجتمعات ضخمة وكبيرة جداً من العملاء والتي لا تكون متاحة عبر قنوات الاتصال التقليدية، حيث تفترض مواقع التواصل الاجتماعي أن تواصل الأفراد فيما بينهم عبرها ذو فعالية أكثر من تواصلهم الشخصي [5].

F. إعلانات الفيديو:

اكتسب استخدام إعلانات الفيديو لتقديم محتوى ترويجي شعبي متزايد وأصبح وسيلة فعالة للتفاعل مع الجمهور.



تُستخدم اليوم الكمية المذهلة من إعلانات الفيديو لنقل الرسائل التجارية إلى المستخدمين عبر الإنترنت. فإنه يتحتم على العميل أن ينتظر ليتم عرض الإعلان أو جزء منه لمدة محددة مثلاً (خمس ثواني) حتى يستطيع تخطيه. كما في الشكل

4 Figure

- إعلان النشر هو شكل محدد من أشكال إعلانات الفيديو التي يتم ضمها إلى محتوى

Video ads 4 Figure

الفيديو الآخر في مواقع الويب المتدفقة مثل YouTube. تظهر مقاطع الفيديو هذه تلقائياً

قبل تشغيل المحتوى الأصلي ويمكن مشاهدتها إما بتسريقات قابلة للتخطي أو غير قابلة للتخطي [6], [7].

واهم ما يميز الإعلانات عبر شبكة الإنترنت عن الإعلانات التقليدية الأخرى هي خاصية التفاعلية والمرونة التي قد لا تكون موجودة أو متوفرة في وسائل الإعلانات التقليدية بالشكل الذي توجد في الإعلانات عبر الإنترنت، فإن هذه الخاصية

تعود بالفائدة على الشركات صاحبة الإعلانات تستطيع من خلالها تتبع العملاء ومراقبتهم ومعرفة ردود أفعالهم وحتى أفكارهم وآرائهم. [8]

ان اهم الفروقات الرئيسية بين الأنواع المختلفة من الوسائل الإعلانية (التلفاز , والراديو , واللوحات الطرقية , والصحف , والمجلات , والإنترنت) كما هو ملخص بالجدول Table 1: [8]

Table 1 أنواع الاعلانات


الوسيلة الاعلانية	مزايا	مساوئ
التلفاز	تغطية السوق المستهدف بشكل واسع ، تجمع بين المؤثرات البصرية والصوتية والحركية بحيث تجذب كل الحواس للعملاء	اختبار أقل للجمهور المستهدف ، تكلفة مرتفعة بشكل عام ، مدة العرض قصيرة
الراديو	قبول محلي جيد ، اختبار جغرافي للجمهور نسبيا مرتفع تكلفة منخفضة	تستخدم فقط المؤثرات الصوتية وبالتالي جذب منخفض ومدة عرض قصيرة تصل الى حجم قليل من الجمهور المستهدف
الصحف	تغطية للسوق المحلية ، مصداقية مرتفعة ، قبول واسع ، مرونة	فترة قصيرة من الإعلان تصل الى حجم قليل من الجمهور المستهدف
المجلات	اختيار الديموغرافي والجغرافي ، مصداقية مرتفعة ، تدوم طويلا ، تبني علاقة جيدة وطويلة الأجل مع العملاء	شراء طويل ، تكلفة مرتفعة لا يوجد ضمانات لقراءة الإعلانات وعد اتلاف البعض منها
البريد المباشر	اختبار مستهدف للجمهور ، يقوم على فكرة التسليم الشخصي	مرتفع التكلفة
الإعلانات الطرقية	مرونة ، تكلفة منخفضة ، اختيار مواقع جيدة ، رسائل تنافسية منخفضة	لا يوجد اختبار جمهور مستهدف التفاعل محدود
شبكة الانترنت	الاستهدافية ، كفاءة التكلفة ، تفاعلية ، توافرية ، مرونة	أثر منخفض نوعا ما ، مصداقية اقل في بعض الأحيان

2.2.3 انشاء الإعلانات للشركة:

يتم انشاء الإعلانات عن منتجات شركة AWC و تعرض على المستخدمين بأنواع متعددة ومتنوعة محققة أكثر رغبات المستخدمين ، ومتناسبة مع طريقة العرض على صفحة الانترنت من موقع الشركة.

وحرصاً على نجاح العملية الاعلانية وتحقيق الشركات لأهدافها من خلال النشاط الإعلاني لجأت بعض الشركات الى استعمال الذكاء الاصطناعي في تطوير العملية الاعلانية لرفع قدرتها على تحديد رغبات المستخدمين

2.3 الذكاء الاصطناعي والتعلم الآلي والتعلم العميق:



يجب أن نفهم علاقة التعلم العميق بالتعلم الآلي والذكاء الاصطناعي. ولعل أفضل طريقة لإظهار هذه العلاقة هي بتوضيحها في هذه الدوائر الثلاث المرسومة [9]. كما في الشكل Figure 5 deep learning

2.3.1 الذكاء الاصطناعي Artificial intelligence:


هو المجال المعني ببناء برامج وخوارزميات قادرة على حل المشاكل وإنجاز المهام المختلفة بكفاءة عالية جداً، عبر الاستلهام من آلية عمل الدماغ البشري في إيجاد حلول المشاكل وإنجاز المهام المختلفة. ظهر مصطلح الذكاء الاصطناعي لأول مرة على يد العالم الأميركي John McCarthy سنة 1956 [10]، ضمن ورشة عمل شهيرة في كلية Dartmouth يُنظر لها على صعيد واسع على أنها نقطة البداية للذكاء الاصطناعي كما نعرفه اليوم.

2.3.2 التعلم الآلي machine learning:

هو مجموعة من البرامج والبيانات والقواعد المعرفة للأنماط من خلال معالجة البيانات المدخلة بكافة الأشكال وتقوم بإيجاد العلاقات والأنماط في البيانات عن طريق تطبيق معادلات إحصائية ورياضية - حيث تتسم كل خوارزمية بصفات مخرجات معينة، لتستطيع تمثيل البيانات بطريقة مختلفة أو التنبؤ بمخرجات لبيانات جديدة - بناءً على العلاقات والأنماط المستنتجة من البيانات المدخلة [9]. حيث تعتمد هذه البرامج على استخدام معلومات قديمة للتنبؤ بما سيحدث في المستقبل تتضمن هذه البرامج أشهر التقنيات والخوارزميات ومنها:

A. العنقدة Cluster:

عنقدة البيانات هي عملية وضع البيانات في مجموعات متماثلة. وخوارزمية العنقدة تقسم مجموعة البيانات إلى عدة مجموعات. حيث أن التشابه بين النقاط ضمن مجموعة معينة أكبر من التشابه بين نقطتين ضمن مجموعتين مختلفتين. فان




فكره تجمع البيانات هي فكره بسيطة في طبيعتها وهي قريبة جدا من الإنسان في طريقه تفكيره حيث اننا كلما تعاملنا مع كمية كبيرة من البيانات نميل إلى تلخيص الكم الهائل من البيانات إلى عدد قليل من المجموعات أو الفئات، وذلك من أجل تسهيل عملية التحليل.

فخوارزميات العنقدة تستخدم على نطاق واسع ليس فقط لتنظيم وتصنيف البيانات وانما هي مفيدة لضغط البيانات وبناء نموذج ترتيب البيانات. حيث أنه إذا كان بإمكاننا أن نجد مجموعات من البيانات، [11] فإنه بالإمكان بناء نموذج لبيانات على أساس تلك المجموعات. تسمى هذه الخوارزميات ب (clustering) مثال على ذلك مجموعة التفاح، ومجموعة الموز

ومجموعة الأجاص حيث يتم استخلاص او ايجاد مجموعة من المكونات المتشابهة فيما بينها بشكل مجاميع، بحيث تكون كل العناصر المتشابهة في مجموعة واحدة مع بعضها. كما في الشكل Cluster6 Figure ومن أهم خوارزميات العنقدة:

I. K-Means:

تصنف خوارزمية K-Means البيانات إلى عدد محدد مسبقاً من العناقيد وهو K عنقود. وتتم عملية اختيار المراكز



K-Means7 Figure

العنقودية في هذه الخوارزمية بشكل عشوائي، ويفضل أن تكون هذه المراكز بعيدة عن بعضها البعض قدر الإمكان. حيث تؤثر نقطة البدء العشوائية على فعالية عملية العنقدة ونتائجها. وتعتمد عملية العنقدة على قيم المراكز الأولية بشكل رئيسي. حيث يتم التركيز على طريقة اختيار مركز


العنقود لتحسين أداء العنقدة في الخوارزمية K-Means كما نستخدم مراكز العناقيد الأولية والتي تم الحصول عليها من البيانات المقسمة على طول محور البيانات وفقاً لأعلى فرق لتعيين مركز العنقود الأفضل [12]. كما في

الشكل K-Means7 Figure

✓ سهل التنفيذ نسبياً.	✓
✓ يتكيف بسهولة مع الأمثلة الجديدة.	
✓ يعمم على مجموعات ذات أشكال وأحجام مختلفة ، مثل العناقيد البيضاوية.	
✗ اختيار k يدوياً.	✗
✗ أن تكون معتمدة على القيم الأولية.	
✗ تجميع البيانات بأحجام وكثافة متفاوتة.	

B. التصنيف classification:

يستخدم التصنيف بشكل واسع في حل الكثير من مشكلات خاصة تلك التي تتعلق بالتسويق من خلال تحليل




Classification8 Figure

مجموعة من البيانات ووضعها على شكل أصناف أو أقسام يمكن استخدامها فيما بعد لتصنيف البيانات مستقبلاً، وهنا يكمن الفرق بين التصنيف وإنشاء العناقيد فالتصنيف يقصد به تقسيم البيانات الى مجاميع يتم انشاءها مسبقاً. كما في

الشكل Classification8 Figure وهناك الكثير من خوارزميات التعلم الآلي التي يمكن استخدامها [11] وسنتطرق لبعض منها:

I. Linear Regression (LR):

ان Linear Regression يدرس العلاقة بين محولات كمية، متحول كمي تابع وترمز له ب Y ومتحول كمي



مستقل ومؤثر في Y نرمز له ب X ، كالعلاقة بين وزن الطفل Y وعمره X أو كالعلاقة بين إنفاق الأسرة Y وعدد أفرادها X الخ. ويتم دراسة مثل هذه العلاقات في المجتمع المفروض يتم سحب عينة عشوائية من عناصره بحجم n عنصر ويأخذ من كل عنصر فيها القياسات المقابلة (x_i, y_i) لكل من X, Y [13]. كما في الشكل LR9 Figure. ونفترض أن الطبيعة العامة للعلاقة بين Y و X هي علاقة سببية، وان الصيغة الرياضية لها في المجتمع هي من الشكل الخطي التالي:


$$Y = \beta_0 + \beta_1 X + \varepsilon \quad \text{Equation 1}$$

حيث أن: ε هو حد الخطأ العشوائي. وأما الأمثال: β_0 و β_1 فهي أعداد حقيقية، تعمل على تحديد وضعية المستقيم في المستوى XOY وبحيث يكون ميله مساوياً ل β_1 وقاطعه مع OY مساوياً ل β_0 لكن بما أن الأمثال β_0 و β_1 مازالت مجهولة فان وضع المستقيم في المستوى يبقى غير محدد.

✓ القدرة على تحديد التأثير النسبي لمتغير تنبؤ واحد أو أكثر على قيمة المعيار. على سبيل المثال قد يجد الوكيل العقاري أن حجم المنازل وعدد غرف النوم يرتبطان ارتباطاً وثيقاً بسعر المنزل.	✓ القدرة على تحديد القيم المتطرفة أو الحالات الشاذة.	✓ يظهر قوته عندما تكون البيانات خطية أو على شكل خط.	✓ ان التعقيد الزمني للانحدار الخطي أقل إلى حد كبير عند مقارنته ببعض خوارزميات التعلم الآلي الأخرى
✗ حساسة للقيم المتطرفة: يمكن أن يكون للقيم المتطرفة تأثير كبير جداً على أداء الانحدار الخطي، وبالتالي يجب التعامل معها بشكل مناسب قبل تطبيق الانحدار الخطي على مجموعة البيانات.	✗ عرضة للضوضاء والتخصيص.		

II. Logistic regression (LOG R):

هو نموذج إحصائي ينتمي لنماذج Linear Regression يمكن من نمذجة متغير ثنائي الحد بدلالة مجموعة من




المتغيرات العشوائية المتوقعة، رقمية كانت أو فئوية. يُستخدم Logistic regression للتنبؤ باحتمالية وقوع حدث ما بمعرفة إضافية لقيم متغيرات يمكن أن تكون مفسرة أو مرتبطة بهذا الحدث [15]. يُستخدم Logistic regression عدة متغيرات مُتَوَقَّعة والتي يمكن أن تكون رقمية أو فئوية. يشتهر Logistic regression أيضاً بتسميات المصنف العام. تستعمل هذه النمذجة بشكل واسع في العديد من التطبيقات العلمية والتجارية وهي من طرق النمذجة الأكثر تطبيقاً في مجال التعلم الآلي، مثل تحديد ما إذا كانت الصورة

تحتوي على قط أو نمر أو سمك، وما إلى ذلك. سيتم تعيين احتمال بين 0 و 1 لكل كائن يتم اكتشافه، بحيث يكون المجموع الكلي يساوي واحد.

✓ سهل الفهم، سهل التنفيذ، وفعال للتدريب	✓ يؤدي أداءً جيداً عندما تكون مجموعة البيانات قابلة للفصل خطياً
✓ دقة جيدة لمجموعات البيانات الأصغر	

III. Naive Bayes classifier (NB):

تعتبر خوارزمية Naive Bayes تقنية تصنيف تعتمد على فرض الاستقلال بين المتنبئين. predictors. بعبارة أخرى، يفترض مصنف Naive Bayes أن وجود ميزة معينة في فئة لا علاقة لها بوجود أي ميزة أخرى. على سبيل المثال، يمكن اعتبار الفاكهة على أنها تقاحة إذا كانت حمراء ودائرية وقطرها حوالي 3 بوصة حتى إذا كانت هذه المزايا تعتمد على بعضها البعض أو على وجود مزايا أخرى، فإن مصنف Naive Bayes سوف يأخذ بعين الاعتبار كل هذه المزايا للمساهمة بشكل مستقل في تنبؤ احتمال أن تكون هذه الفاكهة تقاحة. وتعتبر خوارزمية Naive Bayes سهلة الانشاء ومفيدة بشكل خاص لمجموعات البيانات الكبيرة جداً. إلى جانب البساطة، من المعروف أن Naive Bayes تتفوق في الأداء حتى على طرق التصنيف الأخرى المعقدة. حيث ان: [16]




$$p(c|x) = \frac{p(x|c) * p(c)}{p(x)}$$

$p(c|x)$: الاحتمال العكس
 $p(x|c)$: الاحتمال المسبق
 $p(c)$: فئة الاحتمال المسبق
 $p(x)$: توقع الاحتمال المسبق

✓ سهولة التنفيذ. من السهل تقييم الاحتمالات الشرطية.	✓ سريعة جداً - لا توجد تكرارات لأن الاحتمالات يمكن حسابها مباشرة. لذا فإن هذه التقنية مفيدة حيث تكون سرعة التدريب مهمة.
✓ إذا استمر افتراض الاستقلال المشروط، فقد تعطي نتائج رائعة.	✗ لا يصح افتراض الاستقلال المشروط دائماً. في معظم الحالات، تُظهر الميزة شكلاً من أشكال التبعية.
	✗ مشكلة احتمالية صفرية: عندما نواجه بيانات الاختبار لفئة معينة غير موجودة في بيانات التدريب، فقد ينتهي بنا الأمر مع احتمالات صفرية.

IV. Support Vector Machine (SVR):




تقوم هذه الخوارزمية بإيجاد إطار ما، خطي أو غير خطي، حيث تُحدد دقة الخوارزمية بقدرتها على الفصل بين الصنفين (الفئتين) بحيث تكون أقرب عينة من كلا الصنفين أبعد ما يكون عن بعضهما البعض وهو ما يسمى بالحافة، وبصفة عامة كلما زادت الحافة أو هامش الفصل، كلما قل الخطأ في حالة التعميم لجزء البيانات الغير خاص بمرحلة التدريب. [17] وفي أغلب الأحيان لا يمكن الفصل

بين الصنفين خطياً، وحينها نلجأ لتحويل محاور متجهات لبعد أعلى بحيث يتم الفصل بينهم بسطح. ويراعى في هذا المنظور العبء الحسابي فيتم حساب الضرب القياسي للمتجهات بواسطة دالة المصفوفة، حيث يكون السطح الفاصل معرف بمجموعة من النقاط نتاج ضربهم القياسي مع متجه في الإحداثيات الجديدة (ذات البعد الأعلى) تكون ثابتة. حيث إن عملية تصنيف البيانات تعد من أكثر عمليات تعلم الآلة انتشاراً. بوجود نقاط البيانات التي تنتمي لصف من اثنين، يكون الهدف هو تصنيف نقطة جديدة وتحديد لأي من الصنفين تنتمي. في حالة توافر أكثر من طريقة فصل بين الصنفين، فإنه يتم اختيار الطريقة التي تضمن هامش أوسع بين أقرب نقطتين من صنفين مختلفين كما هو مبين في الشكل SVM.

✓ أداء جيد مع البيانات عالية الأبعاد. يعمل بشكل جيد حتى مع البيانات غير المهيكلة وشبه المهيكلة.	✓
✓ تعمل بشكل فعال مع البيانات القابلة للفصل الخطي أي التي تملك هامش فصل واضح.	✓
✓ تُعطي نتائج أكثر دقة في حال كان عدد مزايا بيانات التدريب كبيرة	✓
✗ لا تعمل بشكل جيد للغاية عندما يكون لدينا مجموعة بيانات كبيرة لأن المدة الزمنية اللازمة لتدريبها عالية.	✗
✗ لا تعمل بشكل جيد للغاية عندما تكون مجموعة البيانات تحوي أخطاء كثيرة , سواء كانت ضجيج noise أثناء جمع البيانات أو متداخلة بشكل كامل.	✗

V. Decision Trees (DT):

يمكن استخدام شجرة القرار لتمثيل وصنع القرارات بشكل مرئي وصريح. أنها أداة تُستخدم بانتظام في التنقيب في




البيانات للحصول على هدف محدد حيث تأخذ البيانات على شكل عقدة ثم تقوم بتقسيمها إلى عقدة أخرى أصغر بحسب ميزة (عمود) التقسيم، حيث تبدأ من عقدة الجذر ثم تنقسم البيانات إلى العقد الفرعية وتُعاود الانقسام إلى عقد فرعية أخرى وصولاً إلى العقدة الورقية التي تعطينا التصنيف. كما هو مبين في الشكل [18]. Decision Tree

✓ هي سهلة الفهم والتفسير، حيث يمكن للأفراد العاديين فهم نماذج شجرة القرار بعد شرح مختصر.	✓
✓ لها قيمة حتى بوجود القليل من البيانات، فمن الممكن تشكيل لمحة مهمة بناءً على توصيف الخبراء للوضع (الوضعيات البديلة والتكاليف) وتفضيلاتهم للمخرجات.	✓
✓ كما انها تسمح بإضافة سيناريوهات جديدة ممكنة.	✓
✓ تساهم في تحديد أسوأ وأفضل قيمة متوقعة للسيناريوهات المختلفة	✓
✗ لا تعمم أشجار القرار المعقدة بشكل جيد على البيانات ويمكن أن تؤدي إلى فرط التجهيز.	✗
✗ غير مستقرة، حيث يمكن أن تؤدي التغييرات الصغيرة في البيانات إلى أشجار قرار مختلفة.	✗

VI. Artificial Neural Networks (ANN):

عبارة عن أنظمة حاسوبية تعتمد من حيث المبدأ على محاكاة عمل عصبونات الدماغ من أجل معالجة البيانات وإنجاز مهام في مجالات متنوعة، وهي من أشهر أنماط وطرق التعلم الآلي الهادف لتوفير خوارزميات وبرمجيات قادرة على التعلم بالخبرة. [19] عندما يتم القول إن الشبكات العصبونية تحاكي آلية عمل العصبونات الحيوية في الدماغ. تأخذ الشبكة العصبونية شكل طبقات متعددة تمتلك كل طبقة منها عدداً معيناً من العصبونات، وأقل عدد ممكن من الطبقات هو ثلاث [20]: طبقة الدخل وطبقة الخرج والطبقة المخفية. تقوم طبقة الدخل باستقبال البيانات التي يجب معالجتها، وبحسب قيم بيانات الدخل سيتم تفعيل عصبونات معينة ضمن طبقة الدخل، التي بدورها ستقوم بتفعيل عصبونات الطبقة المخفية، وهكذا وصولاً حتى طبقة الخرج التي نحصل من خلالها على القرار المتعلق بالمهمة المراد إنجازها. كما في الشكل ANN.




ANN14 Figure

✓ أقل تعقيداً وسهولة في التصميم والصيانة.	✓
---	---

✓ سريعة [أحادي الاتجاه].	
✓ استجابة عالية للبيانات الصعبة.	
✗ لا يمكن استخدامها للتعلّم العميق بسبب عدم وجود طبقات كثيفة والانتشار الخلفي	البيانات

2.3.3 التعلم العميق Deep Learning:


هو فرع من فروع التعلم الآلي، حيث تتعلم الشبكات العصبونية الاصطناعية والخوارزميات المستوحاة من الدماغ البشري من خلال كميات هائلة من البيانات. ويعتبر التعلم العميق جزءاً من مجموعة واسعة من أساليب التعلم الآلي التي تستند إلى تمثيل بيانات التعلم، كما يحتل التعلم العميق صدارة التكنولوجيا، حيث أنه يساهم في تشكيل الأدوات التي نستخدمها لتحقيق مستويات هائلة من الدقة. إن أوجه التقدم التي طرأت على التعلم العميق ساهمت في ازدهار هذه التقنية لدرجة جعلتها تتفوق على البشر في بعض المهام. [19]. إن إضافة الخلايا العصبية إلى بنية الشبكة العصبية وفقاً لتوافر بيانات التدريب أو القوة الحسابية، يفسر جزء كبير من النجاح الأخير للشبكات العصبية من خلال حقيقة أن زيادة توافر البيانات والقوة الحسابية لأجهزة الكمبيوتر الحديثة قد تجاوزت حدود خوارزميات التعلم الآلي التقليدية والتي تقشل في الاستفادة الكاملة مما هو ممكن. تم توضيح هذا الوضع كما في الشكل Figure 15 [19].



التعلم العميق يعتمد على خوارزميات خاصة ومعقدة للغاية، فهو يتطلب تعقيداً وترابطاً شديداً ليستطيع أن يحاكي الطريقة التي يعمل بها الدماغ البشري. وذلك على العكس من خوارزميات تعلم الآلة التي في العادة تكون أكثر بساطة كالتوقع الخطي وشجرة القرارات، والتعلم العميق أيضاً يتطلب تدخلاً بشرياً أقل للغاية من تعلم الآلة [19]، حيث إنه بتكفل بمفرده بعملية استخراج الخصائص أو المزايا Features. ومن أهم الخوارزميات المتبعة:

1. Deep Neural Networks (DNN):

هي شبكة الخلايا العصبية، أو بالتوجه الحديث الشبكة العصبية الاصطناعية تتكون الشبكة العصبية الاصطناعية من خلايا عصبية أو عقد صناعية الشبكة العصبية إما أن تكون شبكة عصبية بيولوجية مصنوعة من أعصاب بيولوجية أو أن تكون شبكة عصبية صناعية لحل مشاكل وقضايا الذكاء الاصطناعي [19]. كما في الشكل DNN.



- ✓ تتميز بنية التعلم العميق بالمرونة بحيث يمكن تكيفها مع المشكلات الجديدة في المستقبل.
- ✓ يمكن إجراء عمليات حسابية متوازية ضخمة باستخدام وحدات معالجة الرسومات GPU وقابلة للتطوير لأحجام كبيرة من البيانات. علاوة على ذلك، فإنه يوفر نتائج أداء أفضل عندما تكون كمية البيانات ضخمة.

✓ تُستخدم للتعلّم العميق بسبب وجود طبقات عديدة متّصلة ببعضها مع إمكانية الانتشار الخلفي لتوفر دقة أكثر لمعالجة البيانات	✗ لا توجد نظرية قياسية لإرشادك في اختيار أدوات التعلم العميق الصحيحة لأنها تتطلب معرفة الطوبولوجيا وطريقة التدريب والمعلومات الأخرى. نتيجة لذلك، من الصعب أن يتم تبنيها من قبل أشخاص أقل مهارة. ✗ معقّدة نسبياً في التصميم والصيانة. ✗ بطيئة نسبياً (تعتمد على عدد الطبقات المخفية).
--	---

2.4 الدراسة البحثية (الدراسات السابقة):

في السنوات الأخيرة، أصبح التعلم العميق والتعلم الآلي من المواضيع المهمة في مجال التسويق نظراً لتوفر المعلومات الرقمية. ومع ذلك، لا يزال هناك العديد من التحديات في هذا المجال، مثل كمية ونوعية البيانات المستخدمة لتدريب النموذج للتنبؤ باستجابة العميل، فمن الصعب تقديم ما يلزم من هذه البيانات بشكل كافٍ وموثوق. فهناك حاجة إلى الكثير من الأمثلة التدريبية لإنشاء نموذج دقيق وقابل للتعميم. فمثلاً في الدراسة [21] تم اعتماد CTR في مجموعة بيانات Criteo Dataset، هذه واحدة من مجموعات البيانات المعيارية المهمة التي تم جمعها من سجلات البيانات الحقيقية لمدة سبعة أيام بواسطة شركة Criteo¹. وإن هذه المجموعة لديها نسخة كاملة ومكثفة من البيانات في العالم الحقيقي. المشكلة الشائعة التي تكثر تكراراً بخصوص مقياس CTR هي مشكلة عدم توازن فئة البيانات حيث يكون عدد النقرات مقارنة بعدد مرات الظهور قليلاً جداً، وتشير بعض الدراسات [21]–[29] إلى أن الاعتماد على CTR لتقييم أداء نتائج البحث في التجارة الإلكترونية يمكن أن يكون مزعجاً ويؤدي إلى نتائج مضللة. على الرغم من أن قيم CTR يمكن أن تُظهر اتجاه العميل فيما يتعلق بالإعلانات التجارية والمنتجات في الأنظمة الموفرة عبر الإنترنت، إلا أنها ليست مؤشراً محدداً لإظهار نجاح الأعمال في اكتساب عملاء جدد.

وتتضمن الدراسة [30] جمع البيانات في الوقت الفعلي عبر المدونات أو مواقع التواصل الاجتماعي مثل Twitter لتخزينها على شكل بيانات ضخمة مثل HDFS أو RDD. وأكدت على وجوب تطبيق طرق معالجة مسبقة مثلاً (إيجاد القيم المفقودة) لقواعد البيانات المعتمدة (Resilient Distributed Datasets) RDD لجعل تلك البيانات قابلة للتدريب، لما تسببه القيم المفقودة من التأثير السلبي على النتيجة. وتم في الدراسة [31] اعتماد Amazon Product Data² حيث تم التركيز على 24 فئة رئيسية، مثل البقالة والكتب والموسيقى الخ.

وهناك أمثلة أخرى عن مجموعات البيانات مثل قواعد بيانات [AWC](#)³ سيتم الشرح عنها في 3.1.1.

حيث تم في الدراسة [32] تصميم النماذج التنبؤية الفعالة والمناسبة مثل مصنّفات HP tree و HP Forest و HP و Neural و HP BN وتقييمهما للتنبؤ بالأحداث المستقبلية. [32] كما أكد Mafas Raheem يوفر التحليل المقارن باستخدام

¹ تم إعداده في البداية للمنافسة التي عقبتها Kaggle في عام 2014 لتشجيع تطوير مناهج مهمة التنبؤ بمعدل النقر.

<https://jmcauley.ucsd.edu/data/amazon/2>

³ Adventure Works Cycle هي شركة تصنيع كبيرة متعددة الجنسيات تنتج بدائل معنوية للدراجات، والتي يتم تصديرها إلى أمريكا الشمالية وأوروبا وآسيا. تستند هذه الدراسة إلى بيانات العملاء الحاليين والعملاء المحتملين الجدد في قاعدة بيانات Adventure Works DW لشركة Adventure Works، بما في ذلك البيانات التاريخية لمشتركي الدراجات البديلة وبيانات مشتركي الدراجات البديلة المتوقعين. تُستخدم البيانات التاريخية لمشتركي الدراجات لبناء واختبار نموذج التنبؤ.

خوارزميات تنبؤية مختلفة دليلاً على أن خوارزمية HP forests عالية الأداء فعالة بشكل خاص في التنبؤ بالأحداث المستقبلية بدقة 80%.

ومن خلال مراجعاتنا للدراسات السابقة، رأينا عدة محاولات لدراسة الإعلانات والتنبؤ باستجابة العميل:

ففي الدراسة [21] تم اختيار (CTR) click-through rate كمثال عملي. واقترح نموذج DNN وهو شبكة عصبية عميقة بهندسة معمارية جديدة، ولتحسين أداء التنبؤ لـ DNN الذي يعمل على البيانات الفئوية من خلال استكشاف تفاعلات المزايا، لقد تم تصميم نوعين من PNN: 1- IPNN يتم بناءً على اختيار العميل للمنتج الداخلي و2- OPNN يتم بناءً على اختيار العميل للمنتج الخارجي. وأظهرت نتائجنا التجريبية أن شبكتي PNN تفوقت على النماذج الحديثة الأخرى. ومن أهم الاستنتاجات من هذه الدراسة أن شبكتي PNN المقترحتين لهما تقارب أفضل من نماذج الشبكات الأخرى. وكما قام Mohbey باستخدام طرق تصنيف مختلفة في الدراسة [30] مثل (Logistic regression, SVM, Naive Bayes)، Random forest classifier، Decision tree) المعروفة للتنبؤ باستجابة العميل لتحديد رغباته. وأظهرت النتائج التجريبية أن Logistic regression لديه دقة أعلى مقارنة بالطرق الأخرى للتنبؤ باستجابة العميل. وتم في الدراسة [31] بناء نموذج الشجرة المقترح للتنبؤ بالتفضيل الموثوق. وتم نقاش كيف يخفف نموذج الشجرة المقترح من المشاكل، مثل الإفراط في التخصص، والبدء البارد، ومتطلبات الوقت الفعلي حيث تم المقارنة بين الخوارزميات (a) proposed-CF، (b) proposed-tree، (c) maxheap-CF، (d) maxheap-tree، (e) matrix-UbCF، and (f) knowledge-CF. وكما هو موضح بالجدول الآتي:

Table 2 جدول مقارنة خوارزميات

	proposed-CF	proposed-tree	maxheap-CF	maxheap-tree	matrix-UbCF	knowledge-CF
PRECISION	58.6%	63.3%	54.7%	57.2%	74.3%	70.8%
RECALL	74.4%	73.7%	70.9%	66.3%	42.4%	62.4%
F_MEASURE	64.3%	66.5%	60.9%	60.3%	51.9%	64.6%
ACCURACY	55.9%	57.9%	52.2%	51.6%	47.5%	54.3%

وكما أكد Kolan الدراسة [33] باستخدام خوارزمية شجرة القرار، يمكن للشركات تقديم إعلاناتها للعملاء المناسبين وتوفير الكثير من الوقت. حيث يتمثل الهدف الرئيسي للدراسة [33] في زيادة احتمالية عرض الإعلان للعميل. عندما يتم تقديم الإعلان المناسب للعميل المباشر، ستزداد احتمالية تفضيله، وبعد ذلك يمكن منح الإعلان شعبية متزايدة بين العملاء. يوفر هذا النهج نطاقاً واسعاً للشركات الضخمة في بيع سلعها، وإنشاء وتقديم الإعلانات المتعلقة بهذه السلع للعملاء. واستخدما Muhammad Junaid و Syed Abbas طريقة Linear Regression للتنبؤ في بحثهما، يتم تجاهل البيانات الفئوية ويتم استخدام جميع المزايا المستمرة مثل عرض الأسعار والكلمات الرئيسية لإظهار العلاقة المباشرة مع CTR [34]. لقد استخدموا عرض الإعلانات السياقية استناداً إلى خوارزمية أعلى عرض تسعير والتي تختار الإعلان بناءً على سياق الناشر بالإضافة إلى الحد الأقصى لعرض التسعير ضمن مجموعة الإعلانات المحددة. ولكن هذه الطريقة تعاني من انخفاض في الكفاءة. عادةً ما تُبنى النماذج الأساسية بناءً على نماذج Logistic regression المصممة بشكل مميز مع مزايا غنية في محاكاة الإنتاج [27]. يعد تسلسل نواقل تضمين المزايا نهج مباشر شائع الاستخدام في العديد من الدراسات [21]. يقارن المؤلفون في [27] أداء النموذج المقترح FFM مع نماذج Logistic regression الأساسية من خلال حساب التحسن النسبي لعائد الاستثمار (ROI) في الإعلانات المصورة.

على الرغم من أن نماذج Logistic regression قد أظهرت قابلية جيدة للتوسع والتفسير للتعامل مع البيانات في صناعة الإعلان عبر الإنترنت [24]، فإن تعميم النموذج للتنبؤ بالعينات الجديدة محدود ويعتمد بشكل كبير على ما يمكن الحصول منه على مزايا عالية الجودة من خلال هندسة المزايا. وتوسعت الدراسة [29] بفكرة تفاعل المزايا فيما يتعلق بمعلومات كل ميزة، لتوفير نموذج هجين من FFM وشبكة عصبية عميقة متصلة بالكامل، لتعلم اقتران المزايا في البيانات المدخلة. حيث يتم تمثيل مزايا الإدخال المنقرقة بواسطة ناقلات تضمين متعددة لمعالجة تأثير الميزة على الحقول الأخرى. كما يوجد جوانب سلبية لنمذجة factorization machines، أحد هذه الجوانب السلبية هو أنه بالنسبة للبيانات الفئوية متعددة الحقول، قد تتأثر قيم المزايا ببعضها، وهذا يغير التفاعل بين المزايا. [27] ومنه نستنتج أن العدد الكبير من المزايا يتسبب بشكل عام في مشكلة تعقيد واختناق الذاكرة [27]. بالإضافة إلى ذلك، قد تواجه النماذج المستندة إلى DNN مشكلة التدرج غير الحساسة عند التعامل مع البيانات الفئوية متعددة الحقول التي تمنع تقدم التحسين المستند إلى التدرج. لمواجهة هذه التحديات، تم اقتراح بنية net-in-net [28] لنمذجة تفاعلات المزايا. وفي الدراسة [21] تم اقتراح هجين جديد من خلال الجمع بين ناقلات التضمين وسلسلة من factorization machines وشبكة MLP. تستفيد هذه الطريقة من قدرة التعلم للشبكات العصبية بطريقة أكثر فعالية من MLPs، من خلال إضافة طبقة بين طبقة التضمين والطبقة الأولى من الشبكة العصبية المتصلة بالكامل. في مراجعتنا رأينا محاولات قليلة مثل [21] لتقديم شبكة عصبية متصلة بالكامل لتوقع استجابة المستخدم. لنمذجة تفاعلات المستخدم مع المكونات الأخرى في سياق عرض الإعلانات، يُقترح شبكة بيرسبترون⁴ متعدد الطبقات للحصول على طبقة مخفية أكبر من خلال مقارنة الهياكل المختلفة. ولكن بشكل عام، لم تتم دراسة هذه العملية جيداً وتعتمد بشكل كبير على الفهم الحدسي للمطورين والمعرفة في مجال التطبيق.

ومن خلال دراستنا تم التوصل إلى مايلي :

1. أن طرق الإعلان Pop-up هي طرق مزعجة لمستخدم الانترنت
2. أن طريقة الإعلان Banner أفضل حيث تزيد من وعي المستخدم
3. أن طرق الإعلانات التقليدية ممكن ان تضيق وقت المستخدم وتسبب هدر لموارد الشركة.
4. طريقة Linear Regression هي ابسط الطرق للتنبؤ باستجابة العميل ولكنها تعاني من انخفاض في الكفاءة.
5. على الرغم من انتشار Logistic regression الواسع الا انه محدود.
6. تخفيف المشاكل باستخدام نموذج الأشجار، مثل الإفراط في التخصص والبدء البارد.
7. قدرة التعلم للشبكات العصبية العميقة كبيرة ولها مستقبل واعد في مجال التنبؤ باستجابة العميل والتسويق الالكتروني.
8. يمكن أن يحقق التعلم العميق أيضاً تأثيرات تطبيقية مهمة على مجموعات بيانات للشركات الاعلانية.
9. العثور على العلاقة بين المزايا من خلال عمليات المنتج الداخلي والمنتج الخارجي.
10. في التنبؤ بمعدل النقر الاعلاني ان شبكتي PNN أفضل من النماذج الأخرى

2.5 الخاتمة:

تم في هذا الفصل في القسم الأول دراسة الإعلانات عبر شبكة الانترنت موضحاً أنواعها وأشكالها وخصائصها وتأثيرها على المستخدمين

⁴ بيرسبترون اسم أطلقه عالم الأعصاب Frank Rosenblatt على مجموعة تجاربه لمحاكاة الدماغ البشري في عملية التفكير بين عامي 1957-1962.

و تم في القسم الثاني باستعراض ودراسة العلاقة بين التعلم العميق بالتعلم الآلي والذكاء الاصطناعي واستعرضنا أهم الخوارزميات المتبعة في مجال التنبؤ بحاجات المستخدمين وتم توضيح أهم المزايا والسلبيات لكل خوارزمية على حده.

وبناء على ذلك يعتبر هذا الفصل نقطة بداية تمهد من أجل دراسة رغبات المستخدمين الشرائية نحو المنتجات المعلن عنها عبر الانترنت، ومعرفة العوامل التي تؤثر على هذه الرغبات، والتي سوف نتطرق لها في الفصول القادمة بإذن الله.



الدراسة التجريبية ومناقشة النتائج

الفصل 3 الدراسة التجريبية ومناقشة النتائج:

3.1 مقدمة:

من خلال دراستنا السابقة لعملية التطوير الإعلاني. في هذا الفصل سنلخص العمل الذي قمنا به، وكيفية الحصول على البيانات لتصبح البيانات جاهزة للتدريب حيث تم دراستها والوصول الى احصائيات تفيدنا مستقبلا في عملية التنبؤ الإعلاني كما تم تشفير البيانات النصية الى رقمية وتقسيمها الى مجموعتي التدريب والاختبار.

3.2 دراسة مراحل التنبؤ بإمكانية استجابة المستخدم:

النموذج المتعامل به لتوقع استجابة المستخدم الموضح في الشكل Figure 17. حيث إنّ إطار العمل يمكن تقسيمه الى قسمين رئيسيين:




Figure 17 Workflow diagram

3.2.1 مرحلة الحصول على قاعدة البيانات وخواصها (Data):

في هذه المرحلة يتم جمع المعلومات وتجهيزها لكي تكون جاهزة لمرحلة التدريب. [35]

Table 3 Data AdventureWorksDW2019

	Column	Data Type	Identity	Nullable
1	CustomerKey	varchar(50)	X	
2	ProductKey	varchar(50)		X
3	ProductSubcategoryKey	varchar(50)		X
4	GeographyKey	varchar(50)		X
5	Age	varchar(50)		X
6	HouseOwnerFlag	varchar(50)		X
7	TotalChildren	varchar(50)		X
8	YearlyIncome	varchar(50)		X
9	Gender	varchar(50)		X
10	MaritalStatus	varchar(50)		X

11	OrderNumber	varchar(50)		X
12	NumberChildrenAtHome	varchar(50)		X
13	NumberCarsOwned	varchar(50)		X
14	BikeBuyer	varchar(50)		X

A. مرحلة الحصول على البيانات:


هناك العديد من الإصدارات المختلفة لقواعد بيانات AWC⁵، المتاحة والتي تشاركها Microsoft لأغراض تعليمية. واستخدمت هذه الدراسة مصدر البيانات Adventure Works DW 2019 حيث تم الحصول على النسخ الاحتياطية الكاملة لها من ([Adventure Works sample databases](#)) Microsoft GitHub. وتم استخراجها واستخدامها عن طريق برنامج SQL Server⁶ [35] ومن ثم عرض البيانات وفلترتها من عدة جداول حيث تم انشاء view يضم عدة جداول وهي vTargetMail, vAssocSeqOrders, vAssocSeqLineItems, ProspectiveBuyer, vTimeSeries

وتم الربط بينهم عن طريق تعليمات SQL Server والحصول على المعلومات المطلوبة حيث: تحتوي قاعدة البيانات على (سجلات - معاملات - مبيعات الإنترنت) لـ AWC جنباً إلى جنب مع التفاصيل للعميل (بيانات مهيكلة). فيتم اتخاذ الميزات التي تتضمن أهم المعلومات عن العميل والمنتجات التي اشتراها بناء على أهميتها وتأثيرها:

GeographyKey, Age, ProductSubcategoryKey, ProductKey, CustomerKey, HouseOwnerFlag, TotalChildren, YearlyIncome, Gender, MaritalStatus, OrderNumber, NumberChildrenAtHome, NumberCarsOwned, BikeBuyer.

وان كل ميزة تؤثر على النتيجة فمثلاً: ان الفئة العمرية الأكثر شراءاً للمنتج المعروف (الدراجة) هي (40 سنة - 60 سنة)، وبالنسبة لعدد الأولاد في المنزل له تأثير فإن الفئة التي لا تملك عدد من الولاد في المنزل هي الأكثر شراءاً للمنتج المعروف (الدراجة)، والفئة التي تملك منزل هي أكثر شراء للمنتج من التي لا تملك منزل، وقد تبين من خلال الاحصائيات الذي يمتلك أقل من (2 سيارة) فإن احتمال شراء هذا المستخدم أكبر من غيره للمنتج كما هو موضح في جدول الاشكال Table 4 احصائيات

Adventure Works Cycle5. وهي شركة تصنيع كبيرة متعددة الجنسيات تنتج بدائل معدنية للدراجات، والتي يتم تصديرها إلى أمريكا الشمالية وأوروبا وآسيا. تستند هذه الدراسة إلى بيانات المستخدمين الحاليين والمستخدمين المحتملين الجدد في قاعدة بيانات Adventure Works DW لشركة Adventure Works، بما في ذلك البيانات التاريخية لمشتري الدراجات وبيانات مشتري الدراجات المتوقعين. تُستخدم البيانات التاريخية لمشتري الدراجات لبناء واختبار نموذج التنبؤ SQL Server 6: تمتلك لغة SQL من إدارة قواعد البيانات بشكل كامل وإجراء جميع العمليات القياسية كإنشاء الجداول وتعبئتها بالبيانات، أو إجراء الاستعلامات عليها وكذلك الربط بين الجداول المختلفة



B. نوعية المزايا:

يتم تكوين بيانات الإدخال النموذجية المدخلة في أنظمة الإعلان عبر الإنترنت بشكل عام كقيم فئوية متعددة الحقول. على عكس المزايا المستمرة التي توجد بشكل عام عند التعامل مع الصور أو الصوتيات، حيث تحتوي بيانات الإدخال على مجموعة من الحقول الفئوية بما في ذلك (العمر والجنس والراتب السنوي وعدد الأولاد والحالة الاجتماعية.....) لوصف المستخدمين والمنتجات المعروضة، ويوجد أنواع مختلفة للمزايا وهي:

- قيم اسمية *Nominal*: *Gender*, *zip codes*.
- قيم ترتيبية *Ordinal*: علامات، عدد السيارات.

C. مرحلة تنظيف البيانات:

بعدما تمكنا من الحصول على البيانات عن طريق برنامج *SQL server*. يجب ان تكون هذه البيانات واضحة ولا يوجد فيها أي خطأ أو قيم مفقودة لان ذلك يآثر على النتائج بشكل كبير لذلك تم فحص البيانات ولم تُظهر أي قيم مفقودة، لم يتم تنفيذ أي عملية تنظيف على مجموعة البيانات هذه، وبالتالي فان البيانات جاهزة لدراسة نوعية المزايا. وتم الحصول على 56049 نقطة من البيانات.

وتمكنا من تحليل البيانات عن طريق برنامج *Visual Studio*⁷ باستخدام ميزة *Analysis Services* وبعد انشاء المشروع وتهيئة الاتصال برنامج *SQL Server*. تم تحديد قاعدة البيانات المراد الاتصال بها وتعين الجدول المذكورة سابقا

3.2.2 مرحلة انشاء وتدريب نماذج التعلم الآلي والتعلم العميق (learning):

بعدما تم الحصول على قاعدة البيانات وتم تجهيزها للتدريب سيتم انشاء وتدريب نماذج خوارزميات *machine learning* باستخدام برامج *SQL server*, *visual studio analysis services* وسيتم انشاء وتدريب نموذج الشبكة العصبية

7 Visual Studio بيئة العمل البرمجية التي سيتم بناء تطبيق الويب من خلالها حيث تدعم التطبيق بأدوات تحكم غنية تسهل على المبرمج عملية الربط بين مكونات المشروع [42].

العميقة deep learning عن طريق استخدام Python والمكتبات التي تدعمها (Sklearn, Matplotlib, Pandas,) Keras, Tensorflow).

A. تحليل نماذج التعلم الآلي machine learning:

في هذا القسم الأول من مرحلة انشاء وتدريب نماذج التعلم الآلي والتعلم العميق (learning) سنناقش قياس دقة التقييم في البيانات باستخدام برامج SQL server, visual studio analysis services لقد قمنا بدراسة أهم خوارزميات التعلم الآلي المتاحة من بين تسع نماذج للتقييم في البيانات في SQL Server يمكن اعتبار أربع منها كنماذج تصنيف [35], [36] وهي:

Structure	DecisionTrees	LogisticRegression	NaiveBayes	NeuralNetwork
Age	Input	Input	Input	Input
Bike Buyer	PredictOnly	PredictOnly	PredictOnly	PredictOnly
Customer Key	Key	Key	Key	Key
Gender	Input	Input	Input	Input
Geography Key	Input	Input	Input	Input
House Owner Flag	Input	Input	Input	Input
Marital Status	Input	Input	Input	Input
Number Cars Owned	Input	Input	Input	Input
Number Children At Ho...	Input	Input	Input	Input
Order Number	Input	Ignore	Ignore	Ignore
Product Key	Input	Input	Input	Input
Product Subcategory ...	Input	Input	Input	Input
Total Children	Input	Input	Input	Input
Yearly Income	Input	Input	Input	Input

Figure31 create model

bike-buyer
CustomerKey
ProductKey
ProductSubcategoryKey
GeographyKey
Age
HouseOwnerFlag
TotalChildren
YearlyIncome
Gender
MaritalStatus
OrderNumber
NumberChildrenAtHome
NumberCarsOwned
BikeBuyer

Figure33 DSV

(Bayes Neural Networks, Decision Trees, Logistic regression, Naive) حيث تم انشاء مشروع⁸ SQL Server Integration Services. [36], [37] باستخدام SQL Server Data Tools. وبعدها تم انشاء Data Source Views كما في الشكل Figure 34 ثم تم اعتماد قاعدة البيانات التي تم الحصول عليها وتم تقسيم البيانات الى قسمين: قسم التدريب وقسم الإختبار حيث كانت نسبة التقسيم 0.1.

بعد ذلك ، تم انشاء نموذجًا باختيار خوارزمية Decision Trees وبعدها اضافة بقية الخوارزميات الثلاثة (Neural Networks ،Naive Bayes ،Logistic regression) كما تعلمنا في [36]. الموضح في الشكل Figure 31 mining model ولكي نستطيع ان نحصل على Mining Accuracy Chart يجب علينا ن نحدد قيمة التنبؤ في الجدول المخصص الموضح في الشكل Figure 31 mining model

Input Selection	Lift Chart	Classification Matrix	Cross Validation
Select predictable mining model columns to show in the lift chart:			
☒ Synchronize Prediction Columns and Values			
Show	Mining Model	Predictable Column Name	Predict Value
☒	Decision_Trees	Bike Buyer	1
☒	Naive_Bayes	Bike Buyer	1
☒	Logistic_Regression	Bike Buyer	1
☒	Neural Network	Bike Buyer	1

Figure32 mining model

Counts for Decision_Trees on Bike Buyer		
Predicted	1 (Actual)	0 (Actual)
1	1059	252
0	599	1492
Counts for Naive_Bayes on Bike Buyer		
Predicted	1 (Actual)	0 (Actual)
1	1193	298
0	465	1446
Counts for Logistic_Regression on Bike Buyer		
Predicted	1 (Actual)	0 (Actual)
1	1116	285
0	542	1459
Counts for Neural Network on Bike Buyer		
Predicted	1 (Actual)	0 (Actual)
1	1055	259
0	603	1485

Figure 34 classification Matrix

سيتم استخدام⁹ classifiatiion Matrix كما في الشكل Figure 33 فيه تصنيف خوارزميات التعلم الآلي مثلا نموذج شجرة القرار، هناك 1492 حالة لم يشتروا المنتج في الواقع وكذلك لم يتوقع فعل ذلك ونسميها توقع صحيح سلبيا نرسم لها ب FN، و هناك 1059 مشترياً فعلياً للمنتج وتم توقع ذلك ونسميها توقع صحيح ايجابي ونرسم لها ب TP، وهناك أيضا 252 حالة لم يشتروا المنتج في الواقع ولكن تم التوقع أنهم سيشتررون المنتج ونسميها توقع خاطئ سلبيا ويرمز لها ب FP، وهناك 599 حالة لم يتوقعهم أن يشتروا وهم في الواقع اشتروا ونسميها توقع خاطئ ايجابي ونرسم لها ب FN. وبناء عليه تم دراسة النتائج باستخدام المعايير المذكورة في الجدول Table 5 basic measures:

basic measures 5 Table

القانون	الشرح
Accuracy	Accuracy هو يحدد عدد المرات التي كانت إجابة النموذج صحيحه (Classifier)
	$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$

8 بعد SQL Server Integration Services - SSIS جزءا من Microsoft SQL Server الذي يهدف إلى تسهيل عملية ترحيل البيانات. حيث إنه مصمم لتكامل البيانات وسير العمل لعمليات الاستخراج والتحويل والتحميل المستخدمة في تخزين البيانات

9 هذه هي المصفوفة الأكثر شيوعا المستخدمة لتقييم فعالية نماذج التقييم في البيانات

Recall	$\text{Recall} = \frac{TP}{TP + FN}$	Recall تقوم بحساب نسبة البيانات التي توقعناها أنها صحيحة ايجابيا من بين جميع البيانات التي توقعنا انها صحيحة (إيجابيا وسلبيا)
Precision	$\text{Precision} = \frac{TP}{TP + FP}$	Precision تقوم بحساب نسبة البيانات التي توقعناها أنها صحيحة ايجابيا من بين جميع البيانات التي توقعنا انها إيجابية (صحية أو خاطئة).
F1 Score	$\text{F1 Score} = \frac{2 * (\text{Recall} * \text{Precision})}{\text{Recall} + \text{Precision}}$	F1 Score هي النتيجة الكاملة لكفاءة ودقة النموذج

Table 6 نتائج تحليل التعلم الآلي machine learning

	accuracy	Recall	precision	F1Score
Decision Trees	0.487360376	0.415131321	0.80778032	0.743131294
Logistic regression	0.487360376	0.433398058	0.796573876	0.749889565
Naive Bayes	0.487360376	0.452065176	0.800134138	0.770072262
Neural Networks	0.487360376	0.415354331	0.802891933	0.738848362

في معظم برامج machine learning يمكن استخدام مكتبات لحساب قيم Accuracy, Recall, precision, F1Score اما في برنامج SQL Server لا نستطيع استخدام المكتبات لذلك تم حسابهم بتطبيق القوانين المذكورة. بعد حساب قيم المعايير نستنتج من الجدول Table 6 ان نتائج التدريب متقاربة بين الخوارزميات التعلم الآلي ولا تتعدى: (Accuracy ≈ 48%), (Recall ≈ 41% – 43%), (Precision ≈ 80%), (F1Score ≈ 73% – 77%).

B. بناء وتدريب الشبكة العصبية العميقة:

وهي مرحلة تتم بمعزل عن عمل النظام *offline*، يتم فيها بناء وتدريب نموذج الشبكة العصبية على البيانات المهيئة مسبقاً للتدريب، تم استخدام لغة *python* والمكتبات التي تدعمها لعدة أسباب:

- قوة ومرونة لغة *python* في مجال تدريب النماذج
 - وجود عدة مكتبات تدعمها وتسهل الوصول الى النتيجة بأسرع وقت ممكن
 - عدم دعم SQL Server Integration Services للشبكات العصبية العميقة
- وحتى يتم الاستخدام الأمثل للشبكة يجب علينا معالجة البيانات على عدة مراحل قبل إدخالها الى التدريب (مرحلة تشفير البيانات – مرحلة تقسيم البيانات – مرحلة *MinMaxScaler*) وفي ما يلي سنتحدث عن هذه المراحل:

I. مرحلة تشفير البيانات:

حتى نستفيد الاستفادة العظمى من البيانات ولا يتم تجاهل أي معلومة نصية يجب علينا استخدام أنظمة التشفير. حيث ان بعض المزايا التي تم جلبها من قاعدة البيانات تكون نصية مثل الحالة الاجتماعية (متزوج M اعازب S) والجنس (ذكر M \ انثى F) ان طبقة الادخال في نموذج الشبكة العصبية لا تقبل ان تكون البيانات نصية لذلك نلجأ لتشفيرها باستخدام *label_encoder* لتعيين المستويات الترتيبية للبيانات الفئوية حتى نتمكن من ادخال البيانات للتدريب بالشكل الصحيح على شبكة التعلم العميق، في المرحلة القادمة نشرح كيفية تقسيم البيانات

II. مرحلة تقسيم البيانات:

في هذه المرحلة تم فصل مزايا الدخل عن ميزة الخرج الى (X, Y) . يتم التخزين في المتحول X مزايا الدخل التي تتضمن المعلومات عن المستخدم وعن المنتج والمتحول Y فيه النتيجة شراء المستخدم للمنتج ام لا، بهذا نكون قد وصلنا إلى الخطوة الأخيرة في تقسيم البيانات، وهي تقسيم مجموعة البيانات الخاصة بنا إلى مجموعة تدريب ومجموعة اختبار وذلك باستخدام التابع `train_test_split` من مكتبة `scikit-learn`.

وبه يكون تم تعيين 5604 `X_train, X_test, y_train, y_test = train_test_split(X, Y, test_size = 0.1)`

نقطة للاختبار و 50,445 نقطة للتدريب عن طريق التابع المذكور فيكون العدد المخصص للاختبار كافي. وفي المرحلة القادمة نستكشف كيفية جعل البيانات ضمن نطاق واحد.

III. مرحلة MinMaxScaler:

بعد ان تم تقسيم البيانات الى مجموعة تدريب ومجموعة اختبار وصلنا إلى الخطوة الأخيرة في معالجة البيانات

```
14 data.values
executed in 22ms, finished 13:58:26 2021-12-10
array([[18279, 214, 31, ..., 0, 1, 0],
       [18279, 214, 31, ..., 0, 1, 0],
       [18597, 214, 31, ..., 0, 1, 1],
       ...,
       [16580, 606, 2, ..., 4, 2, 1],
       [11250, 606, 2, ..., 4, 2, 1],
       [23358, 606, 2, ..., 0, 2, 1]], dtype=int64)
```

Figure36 data values

نلاحظ من القيم الظاهرة في الشكل أن قيم البيانات في بعض المزايا تصل الى الألاف بينما مزايا أخرى تأخذ 1,2,3,4، وهذا الاختلاف في القيم يجعل من الصعب تهيئة الشبكة العصبية والذي يتسبب ببعض المشاكل العملية لذلك يجب اجراء عملية MinMaxScaler أي جعل

جميع قيم مزايا الدخل ضمن مجال واحد بين 0 - 1 ويتم ذلك من خلال استخدام المكتبات الموجودة

في preprocessing ضمن مكتبة sklearn واستدعاء التابع MinMaxScaler وأخيراً تخزين المصفوفة الناتجة واسنادها الى X .

IV. بناء نموذج الشبكة العصبية:

أن تدريب الشبكة يتضمن تحديد بنية نموذج الشبكة ومن ثم إيجاد أفضل المعلومات للنموذج.

حتى يتم إنشاء بنية الشبكة، يجب التفكير أولاً في نوع بنية الشبكة العصبية التي نريدها. لنفترض أننا نريد الشبكة العصبية الممثلة في Figure 36 Deep Neural




Figure37 Deep Neural Network

Network

أي اننا نريد أربع طبقات كاملة الاتصال *Dense* وهم:

• **طبقة الدخل:** تحوي 512 عصبون، ونطبق عليها تابع التنغيع وحدة التصحيح الخطي ريلو *ReLU*.

• **طبقة خفية-1:** تحوي 384 عصبون، ونطبق عليها تابع التنغيع وحدة التصحيح الخطي ريلو *ReLU*.

• **طبقة خفية-2:** تحوي 256 عصبون، ونطبق عليها تابع التنغيع وحدة التصحيح الخطي ريلو *ReLU*.

• **طبقة خفية-3:** تحوي 128 عصبون، ونطبق عليها تابع التنغيع وحدة التصحيح الخطي ريلو *ReLU*.

• **طبقة الخرج:** تحوي عصبون وحيد، ونطبق عليها تابع التنغيع سيغمويد *Sigmoid*.

```
model = Sequential([
    Dense(512, activation='relu', input_shape=X_train.shape[1]),
    BatchNormalization(),
    Dropout(0.3),

    Dense(384, activation='relu'),
    BatchNormalization(),
    Dropout(0.3),

    Dense(256, activation='relu'),
    BatchNormalization(),
    Dropout(0.3),

    Dense(128, activation='relu'),
    BatchNormalization(),
    Dropout(0.3),

    Dense(1, activation='sigmoid')
])
```

Figure 38 model

ان كتابة كود البرمجي يتطلب أولاً تضمين المكتبات البرمجية الضرورية من مكتبة كيراس *Keras* ومن ثم تخزين النموذج في *model* والذي سنقوم بوصفه بالتسلسل (طبقة تلو الأخرى) بين الأقواس المربعة. كما هو مبين في *Figure 37 model*. ومن احد أهم التحديات التي واجهتنا هي "الملاءمة الزائدة" يوجد لدينا عدة طرق لتلافيها سنستعرض أهمها:

1st Batch normalization

هي طريقة تُستخدم لجعل الشبكات العصبية الاصطناعية أسرع وأكثر ثباتاً من خلال تسوية أو معالجة مدخلات الطبقات عن طريق إعادة التمرکز وإعادة التوسع. [38].

2nd Dropout

تقوم طبقة *Dropout* بتعيين وحدات الإدخال بشكل عشوائي على 0 مع معدل تكرار في كل خطوة أثناء وقت التدريب ، مما يساعد على منع فرط التجهيز. فمثلاً *Dropout(0.3)* أن العصبونات في الطبقة السابقة لديها احتمال 0.3 في التعطل أثناء التدريب [39].

V. تهيئة النموذج:

يتم تهيئة النموذج من خلال تحديد خوارزمية التحسين وتابع الخسارة والمقاييس الأخرى التي نريد تطبيقها. بهذه

```
# Compile model
model.compile(loss='binary_crossentropy',
              optimizer=Adam(learning_rate=0.001,beta_1=0.9,beta_2=0.999,epsilon=1E-5),
              metrics=['accuracy'])
```

Figure39 model compile

الإعدادات المذكورة سابقاً تتطلب استدعاء التابع *model.compile* وذلك بالشكل التالي. حيث تم تحديد *"binary_crossentropy"* كتابع خسارة للمخرجات التي تأخذ

القيم 1 أو 0. والسطر الثالث تم اعتماد خوارزمية *Adam()* كخوارزمية التحسين حيث تم تعيين البارامترات *(learning_rate=0.001, beta_1=0.9, beta_2=0.999)*. [40]

```
checkpoint_path = "cp.ckpt"
# Create a callback that saves the model's weights
cp_callback = ModelCheckpoint(filepath=checkpoint_path,
                              save_weights_only=True,
                              save_best_only=True,
                              verbose=1)
```

Figure40 save best result

وفي ما يلي تابع يتم فيه حفظ احسن نتيجة وحفظ الأوزان للنموذج أثناء تدريب نموذج الشبكة العصبية العميقة. كما في الشكل Figure

save best result40

VI. تدريب نموذج الشبكة العصبية:

بكتابة سطر واحد من التعليمات البرمجية يتم فيه استدعاء التابع *model.fit* لتجهيز معاملات الشبكة أي تحديد البيانات التي نريد تدريب الشبكة عليها وهي *X_train, Y_train* ومن ثم تحديد حجم الدفعة (*batch_size*) ب128 واختيار عدد مرات التدريب *epochs=650* وفي النهاية، يتم استدعاء تابع *callbacks=[cp_callback]* ليتم حفظ أفضل الأوزان لنموذج الشبكة.

C. اختبار نموذج الشبكة

```
# evaluate the model
scores = model.evaluate(X_test, y_test)
y_pred = model.predict(X_test)

print("%s: %.2f%%" % (model.metrics_names[1], scores[1]*100))
print(model.summary())
```

Figure41 train

بعد الإنتهاء من المرحلة التدريب يجب علينا ان نختبر نموذج الشبكة المقترح عن طريق تدريب النموذج ومقارنة النتائج التي حصل عليها

I. بنية النموذج المقترح - التعلم العميق -

بالاعتماد على الشكل *Figure 37 model* يتم استخدام 4 طبقات من الشبكات العصبونية في بناء النموذج وبعد التنفيذ وباستخدام تعليمة *model.summary* يكون بنية النموذج كما في الشكل *Figure 42 model summary*

Figure 42 model summary

D. حفظ نموذج:

بعد الانتهاء من تدريب النموذج، يتم حفظ النموذج لاستخدامه في ما بعد، يتم تخزين خرج هذه المرحلة لتستخدم فيما بعد بتطبيق آخر لمعرفة تنبؤات المستخدم بما يرغب شراءه.

```
# serialize weights to HDF5
n = scores[1]*100
model.save_weights("model.h5")
print("Saved model to disk")
```

Figure 43 Save model

3.2.3 الخطوات ضمن هذه المرحلة:

تكون الخطوات ضمن هذه المرحلة كالتالي:

1. نقوم بمرحلة التعامل مع البيانات بتشكيل مصفوفة بما اشتراه العملاء سابقاً مع المعلومات عن كل عميل وفقاً للبيانات المخزنة في قاعدة بيانات النظام.
2. يتم تمرير خرج المرحلة السابقة وهي مصفوفة المشتريات إلى الوحدة المسؤولة عن انتقاء المنتج المناسب لكل عميل.

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 512)	7168
batch_normalization (Batch Normalization)	(None, 512)	0
dense_1 (Dense)	(None, 384)	106992
batch_normalization_1 (Batch Normalization)	(None, 384)	0
dense_2 (Dense)	(None, 256)	98560
batch_normalization_2 (Batch Normalization)	(None, 256)	0
dense_3 (Dense)	(None, 128)	32896
batch_normalization_3 (Batch Normalization)	(None, 128)	0
dense_4 (Dense)	(None, 1)	128

3. إرسال المعلومات اللازمة للقيام بالتنبؤ برغبة المستخدم إلى الوحدة المسؤولة عن هذه العملية.
4. تعيد هذه الوحدة قيم الترابط المحسوبة وفق أحد المقاييس المنتقاة (وهو في حالتنا المستخدم).
5. بعد أن تقوم الوحدة المسؤولة بحساب التنبؤ لكل مستخدم، يتم تخزين هذه النتيجة في قاعدة البيانات لتستخدم فيما بعد بعملية انتقاء إعلان عن المنتج المتنبئ به للمستخدم المناسب.

3.3 مرحلة عرض الإعلانات:

بعد مرحلة التنبؤ برغبات المستخدمين للمنتجات، يتم عرض الإعلان لكل مستخدم بما يناسبه. وتكون الخطوات ضمن هذه المرحلة كالتالي:

3.3.1 الخطوات ضمن هذه المرحلة

1. يُطلب من النظام تشكيل قائمة بالإعلانات الخاصة بمستخدم معين.
2. يتم تحصيل المعلومات اللازمة لعرض الاعلان والمتعلقة بهذا المستخدم من قاعدة البيانات، كالمنتجات القابلة للتنبؤ باستجابة المستخدم لشرائها.
3. يتم تحصيل هذه المعلومات وتجهيزها ضمن قائمة خاصة بالمرحلة التالية.
4. يتم إرسال هذه المعلومات المتعلقة بالمستخدم والمنتجات القابلة للتنبؤ إلى الوحدة المسؤولة عن حساب التنبؤات.
5. بعد أن يُجرى التنبؤ بشراء المستخدم للمنتجات السابقة وفق آليات التنبؤ المتبعة في النظام، تعيد هذه الوحدة التنبؤات المحسوبة إلى الوحدة المسؤولة عن الإعلان.
6. يجري عرض الإعلان في المكان المناسب عن المنتجات الأكثر ملائمة للمستخدم، التي تم التنبؤ بها من قبل النظام.

3.4 تقارير عن الأداء والنتائج:

نستعرض فيما يلي إحصائيات تبين دقة النموذج المقترح في التنبؤ برغبات العملاء في النظام حسب المعايير (*Accuracy*, *Precision*, *Recall*, *F1-Score*) وباستخدام توابع من مكتبات لغة *python*¹⁰:

```
1 py_pred = loaded_model.predict(X_test)
2 fpr, tpr, thresholds = roc_curve(y_test, y_pred.round())
3 print("accuracy:\t\t", accuracy_score(y_test, y_pred.round()))
4 print("precision_score:\t", precision_score(y_test, y_pred.round()))
5 print("recall_score:\t\t", recall_score(y_test, y_pred.round()))
6 print("f1_score:\t\t", f1_score(y_test, y_pred.round()))
7 print("matthews_corcoef(KC):\t", matthews_corcoef(y_test, y_pred.round()))
8 print("ROC_AUC:\t\t", auc(fpr, tpr))
9 print("classification_report:\t", classification_report(y_test, y_pred.round()))
```

Figure 44 results

```
accuracy: 0.979125780530776
precision_score: 0.974587897200069
recall_score: 0.975822434382237
f1_score: 0.975068115700479
matthews_corcoef(KC): 0.9786741881917229
ROC_AUC: 0.980125780530776
classification_report:
  precision    recall  f1-score   support
0         0.98         0.98         0.98        3247
1         0.97         0.98         0.98        2358
 accuracy
macro avg  0.98         0.98         0.98        5605
weighted avg 0.98         0.98         0.98        5605
```

ويتم ذلك من خلال استخدام preprocessing ضمن مكتبة sklearn واستدعاء التوابع *precision_score*, *f1_score*, *accuracy_score*, *recall_score*, *classification_report*.

وتم حساب القيم للمعايير وتم اظهار النتائج في الجدول: Table 7full results:

Table 7full results

	accuracy	Recall	precision	F1Score
Decision Trees	≈48.736%	≈41.513%	≈80.778%	≈74.313%
Logistic regression	≈48.736%	≈43.340%	≈79.657%	≈74.988%
Naive Bayes	≈48.736%	≈45.206%	≈80.013%	≈77.007%
Neural Networks	≈48.736%	≈41.535%	≈80.289%	≈73.884%
<i>Deep Neural Network</i>	≈97.912%	≈97.582%	≈97.458%	≈97.520%

وبالمقارنة مع جدول *Table 6* نستنتج:

تم في هذه الدراسة انشاء خمسة نماذج تنبؤية كان افضل نموذج هو النموذج المقترح المبني على خوارزميات التعلم العميق للتنبؤ حيث حقق نسب أعلى في نتائج الاختبار من نماذج التعلم الألي.

3.5 عرض بنية النموذج المقترح والمعلومات:

تم بناء نموذج الشبكة *DNN* حيث تم انشاء أربع طبقات باستخدام مكتبات *tensorflow-keras* بعدد العصبونات (512 – 384 – 256 – 128) وطبقة للخرج بعصبون واحد وبدعم *Batch Normalization* و *Dropout* يعرض الجدول التالي البنية النهائية والمعلومات الفائقة لنموذج *DNN*. كما في الجدول *Table 8* حصل النموذج على درجة دقة ممتازة.


Hyper-parameters		
activation	Hidden Layer	relu
	Output Layer	sigmoid
optimizer	adam	
loss	binary_crossentropy	
metrics	Accuracy	
Normalization	Batch Normalization	
dropout_rate	0.3	

Table 8البنية النهائية والمعلومات


Input layer = (input_dim = 18)		
Architecture	Hidden Layer (HL)	
	Neurons	HL 1 = 512
		HL 2 = 384
		HL 3 = 256
		HL 4 = 128
		Output Layer = 1 (Neurons = 1)

10 إحدى لغات البرمجة المصنفة ضمن اللغات عالية المستوى والموجهة للكائنات، وتتميز بأنها ذات بنية سهلة التعلم والاستخدام للمبتدئين، لذلك فإنها تعد اللغة الأكثر ملاءمة لكل شخص ينوي الانخراط في عالم البرمجة للمرة الأولى [43].

3.6 النموذج البياني التفصيلي لدقة النموذج المقترح:



accuracy46 Figure



loss46 Figure

تُقدم لغة *python* تشكيلة واسعة من المكتبات المختصة بعرض البيانات مثل مكتبات *Bokeh*، *ggplot*، *Seaborn*، *Plotly*، وأشهر هذه المكتبات هي *Matplotlib* وهي مختصة برسومات *2D*، وعلى الرغم من أن هذه المكتبة هي من أقدم المكتبات المختصة بالإظهار المرئي للبيانات، إلا أنها ما زالت تتربع على عرش المكتبات المستخدمة في هذا المجال وفيما يلي الشكل البياني للنموذج يبين المخطط البياني للنموذج (*Accuracy, loss*). [41] ونلاحظ في الشكلين *Figure 45* و *Figure 46* تقارب منحنيات *Accuracy* في القسمين *Train, test* ومنحنيات *loss* في القسمين *Train, test* ومنه نستنتج أن نتيجة التدريب ممتازة حيث وصلت الدقة إلى **97.912%** تقريباً.

3.7 الخاتمة

تم في هذا الفصل الدراسة التجريبية للعمل الذي قمنا به من خلال إنشاء وتدريب نماذج التعلم ومقارنة النتائج وتم استنتاج عدة نقاط أهمها:

- دراسة عرض الإعلانات عن منتجات معينة بعد التنبؤ باستجابة المستخدم لشراء المنتج المعلن عنه.
- دراسة تأثير أهم أنواع الإعلانات والمنصات الاعلانية على المستخدم للانترنت سلباً أو إيجاباً.
- دراسة أهم خوارزميات التعلم الآلي والتعلم العميق وتطورها.
- حقق النموذج المقترح للشبكة العصبية العميقة $Accuracy \approx 97.912\%$ وهذا يدل على كفاءة النموذج المقترح.
- برز النموذج المقترح كنموذج تنبؤي واعد في مجال التسويق الالكتروني.
- حفظ زمن المستخدمين باطلاعهم على الاعلانات المفيدة لهم فقط، وجعل التسويق فعال في شركات الاعلان.



الآفاق المستقبلية والتحديات التي واجهتنا والخلاصة

الفصل 4 الآفاق المستقبلية والبحريات التي واجهتنا والتحلاصة:

4.1 مقدمة:

بناء على ما سبق يتم في هذا الفصل عرض التحديات التي واجهتنا و الآفاق المستقبلية لهذه الدراسة.

4.2 التحديات التي واجهتنا

تُظهر العديد من الأساليب، مثل أساليب التعلم العميق والتعلم الآلي، إمكانيات كبيرة لتقدير استجابة العملاء بدقة [25], [27] لكن طبيعة البيانات الكثيفة ومتطلبات الوقت الفعلي جعلت التنبؤ الدقيق باستجابة العميل للإعلان عبر الإنترنت صعب جداً. وهنا نلخص بإيجاز التحديات الرئيسية على النحو التالي:

4.2.1 قابلية التوسع Scalability:

في أنظمة الإعلان في العالم الحقيقي، يكون عدد صفحات الويب التي تمت زيارتها كبيراً للغاية. من خلال الجمع بين عوامل مثل عدد العملاء وكمية الإعلانات، ينتج عنه مجموعة بيانات عملاقة للتحليل. في العديد من الدراسات [42] تم تطبيق التعلم الآلي للتنبؤ باستجابة العميل وتعزيز تخصيص الإعلانات الرقمية.

4.2.2 تباين البيانات Data sparsity:

تتبع هذه المشكلة في الإعلان عبر الإنترنت وأنظمة التنبؤ من أن غالبية بيانات الإدخال من مزايا فئوية تحتاج إلى استخدام التمثيل الثنائي، مما يؤدي إلى متجهات عالية الأبعاد بقيم قليلة جداً غير صفرية. مما يعني أن غالبية العملاء يتفاعلون مع عدد صغير من العناصر والمنتجات.

4.2.3 البداية الباردة Cold start:

هذا تحدٍ شائع للإعلانات والمنتجات والخدمات الجديدة، لأنه لا توجد معلومات سابقة للمستخدم متاحة للاستخدام في التقدير. [43]

4.2.4 ملكية البيانات:

أحياناً نحتاج إلى بيانات غير مُخزنة في مكان ثابت ولا تنتمي لمؤسسة بمفردها مما يتطلب منا تطوير تقنيات لتوزيع تلك البيانات بأمان.

4.2.5 خصوصية البيانات:

خصوصية البيانات هي جزء من العملية التي تركز على الالتزام بالقوانين والتنظيمات التي تخص حماية البيانات. خصوصية البيانات تتمحور حول الطريقة التي يتم بها جمع البيانات، أو تخزينها، أو إدارتها، أو مشاركتها مع جهات الطرف الثالث بما يتماشى مع القوانين المحلية أو الدولية التي تنظم كل هذه العمليات.

4.2.6 التحليل غير التقليدي:

العديد من طرق التحليل تتطلب تقييم الآلاف من الفرضيات واستحداث عدد كبير آخر منها وبالتالي لابد من تحديث تقنيات التنقيب في البيانات من أجل تطوير تلك الفرضيات آلياً في المستقبل.

4.2.7 فيروس الكورونا COVID-19:

تشكل جائحة فيروس الكورونا COVID-19 صدمة اقتصادية واجتماعية شديدة على جميع البلدان على حد سواء. ومع تباطؤ النمو الذي كان يشهده العالم ما قبل الجائحة وارتفاع معدلات البطالة بين الشباب والنساء، فإنه من المتوقع أن تكون هذه الصدمة أكثر حدة [44]. وتشير التوقعات إلى أن الجائحة ستؤدي على الأرجح إلى ركود عالمي عميق على المدى الطويل، كما تم إلغاء المؤتمرات البحثية في مختلف المناطق بسبب المخاوف المتعلقة بالوباء، وهو ما يعوق عمل العلماء، وخاصةً من لا يزال منهم في بداية حياته المهنية. كما يُؤثر على الحصول على المراجع وجمع البيانات.

4.3 الآفاق المستقبلية:

في الختام نقترح مجموعة من المواضيع البحثية التي يمكن أن تطور وأن تغني مجال التسويق كما يلي:

- التنبؤ باستجابة الزائر (مستخدم انترنت بدون تسجيل معلوماته الشخصية) عن طريق ال IP address
- توسيع حجم البيانات للتدريب من خلال الحصول على المزيد من data بشكل أكبر ودراسة التنبؤ عليها.

4.4 الخاتمة:

تم بفضل الله اكمال بناء نموذج يخدم العملية الاعلانية بإبتكار طرق متطورة للتنبؤ باحتياجات المستخدمين، حيث أن مخرجات هذا النموذج عبارة عن قواعد تم استخدامها في نموذج التصنيف للبيانات، وهو يصلح لأن تستخدمه الشركات للتنبؤ برغبات المستخدمين.

4.5 المراجع:

- [1] J. Wang, W. Zhang, and S. Yuan, "Display advertising with real-time bidding (RTB) and behavioural targeting," *Foundations and Trends in Information Retrieval*, vol. 11, no. 4–5, pp. 297–435, 2016, doi: 10.1561/1500000049.
- [2] T. Tavor, "ONLINE ADVERTISING DEVELOPMENT AND THEIR ECONOMIC EFFECTIVENESS," *Australian Journal of Business and Management Research*, vol. 01, no. 06, pp. 121–133, Jan. 2012, doi: 10.52283/NSWRCA.AJBMR.20110106A13.
- [3] S. Rinta-Kanto, "The effect of traditional advertising campaigns on online affiliate channel performance - a case of a leading international hotel booking website," *undefined*, 2012.
- [4] Z. Jiang, S. Gao, and W. Dai, "Research on CTR prediction for contextual advertising based on deep architecture model," *Control Engineering and Applied Informatics*, vol. 18, no. 1, pp. 11–19, 2016.
- [5] J. Aguilar and G. Garcia, "An Adaptive Intelligent Management System of Advertising for Social Networks: A Case Study of Facebook," *IEEE Transactions on Computational Social Systems*, vol. 5, no. 1, pp. 20–32, Mar. 2018, doi: 10.1109/TCSS.2017.2759188.
- [6] T. Mei, X. S. Hua, L. Yang, and S. Li, "VideoSense: Towards effective online video advertising," *Proceedings of the ACM International Multimedia Conference and Exhibition*, pp. 1075–1084, 2007, doi: 10.1145/1291233.1291467.
- [7] P. Covington, J. Adams, and E. Sargin, "Deep neural networks for youtube recommendations," *RecSys 2016 - Proceedings of the 10th ACM Conference on Recommender Systems*, pp. 191–198, Sep. 2016, doi: 10.1145/2959100.2959190.
- [8] ibrahim moselli, "محددات اتجاهات العملاء نحو الاعلانات عبر شبكة الانترنت في سلوكهم الاستجابي. 2015,"
- [9] R. Y. Choi, A. S. Coyner, J. Kalpathy-Cramer, M. F. Chiang, and J. Peter Campbell, "Introduction to Machine Learning, Neural Networks, and Deep Learning," *Translational Vision Science & Technology*, vol. 9, no. 2, pp. 14–14, Jan. 2020, doi: 10.1167/TVST.9.2.14.
- [10] "Artificial Intelligence (Stanford Encyclopedia of Philosophy)." <https://plato.stanford.edu/entries/artificial-intelligence/#HistAI> (accessed Nov. 23, 2021).
- [11] Jiawei. Han and Micheline. Kamber, *Data mining : concepts and techniques*. Elsevier, 2012.
- [12] "Clustering in Machine Learning | Google Developers." <https://developers.google.com/machine-learning/clustering> (accessed Nov. 28, 2021).
- [13] (PDF) "الجزء الثالث -الانحدار الخطي المتعدد والارتباط القانوني ." https://www.researchgate.net/publication/339483559_aljz_althalth_-_alanhdar_alkhty_almtdd_walartbat_alqanwny (accessed Nov. 27, 2021).
- [14] DOUGLAS C. MONTGOMERY, ELIZABETH A. PECK, and G. GEOFFREY VINING, "INTRODUCTION TO LINEAR REGRESSION ANALYSIS," 2012.
- [15] Y. Yuan, F. Wang, J. Li, and R. Qin, "A survey on real time bidding advertising," *Proceedings of 2014 IEEE International Conference on Service Operations and Logistics, and Informatics, SOLI 2014*, pp. 418–423, Nov. 2014, doi: 10.1109/SOLI.2014.6960761.

- Sunil Ray, "Learn Naive Bayes Algorithm | Naive Bayes Classifier Examples," 2017. [16]
<https://www.analyticsvidhya.com/blog/2017/09/naive-bayes-explained/> (accessed Nov. 18, 2021).
- Sunil Ray, "SVM | Support Vector Machine Algorithm in Machine Learning," 2017. [17]
<https://www.analyticsvidhya.com/blog/2017/09/understaing-support-vector-machine-example-code/> (accessed Nov. 18, 2021).
- A. Navada, A. N. Ansari, S. Patil, and B. A. Sonkamble, "Overview of use of decision tree algorithms in machine learning," *Proceedings - 2011 IEEE Control and System Graduate Research Colloquium, ICSGRC 2011*, pp. 37–42, 2011, doi: 10.1109/ICSGRC.2011.5991826. [18]
- C. C. Aggarwal, "Neural networks and deep learning : a textbook," p. 497, 2018. [19]
- "Neural Networks CMPUT 366: Intelligent Systems," 2017. [20]
- Y. Qu *et al.*, "Product-based Neural Networks for User Response Prediction," *Proceedings - IEEE International Conference on Data Mining, ICDM*, pp. 1149–1154, Nov. 2016, Accessed: Sep. 07, 2021. [Online]. Available: <https://arxiv.org/abs/1611.00144v1> [21]
- H. Zheng, D. Wang, Q. Zhang, H. Li, and T. Yang, "Do clicks measure recommendation relevancy? An empirical user study," *RecSys'10 - Proceedings of the 4th ACM Conference on Recommender Systems*, pp. 249–252, 2010, doi: 10.1145/1864708.1864759. [22]
- R. Kumar, M. Kumar, N. Shah, and C. Faloutsos, "Did We Get It Right? Predicting Query Performance in E-commerce Search," *CEUR Workshop Proceedings*, vol. 2319, Aug. 2018, doi: 10.1145/nnnnnnnn.nnnnnnnn. [23]
- O. Chapelle, E. Manavoglu, and R. Rosales, "Simple and Scalable Response Prediction for Display Advertising," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 5, no. 4, Dec. 2014, doi: 10.1145/2532128. [24]
- H. Guo, R. Tang, Y. Ye, Z. Li, and X. He, "DeepFM: A factorization-machine based neural network for CTR prediction," in *IJCAI International Joint Conference on Artificial Intelligence*, Mar. 2017, vol. 0, pp. 1725–1731. doi: 10.24963/ijcai.2017/239. [25]
- H. Guo, R. Tang, Y. Ye, Z. Li, X. He, and Z. Dong, "DeepFM: An End-to-End Wide & Deep Learning Framework for CTR Prediction," Apr. 2018, Accessed: Nov. 22, 2021. [Online]. Available: <https://arxiv.org/abs/1804.04950v2> [26]
- Y. Juan, D. Lefortier, and O. Chapelle, "Field-aware Factorization Machines in a Real-world Online Advertising System," *26th International World Wide Web Conference 2017, WWW 2017 Companion*, pp. 680–688, Jan. 2017, Accessed: Sep. 07, 2021. [Online]. Available: <https://arxiv.org/abs/1701.04099v3> [27]
- Y. Qu *et al.*, "Product-based Neural Networks for User Response Prediction over Multi-field Categorical Data," *ACM Transactions on Information Systems*, vol. 37, no. 1, Jul. 2018, doi: 10.1145/3233770. [28]
- Y. Yang, B. Xu, S. Shen, F. Shen, and J. Zhao, "Operation-aware Neural Networks for User Response Prediction," *Neural Networks*, vol. 121, pp. 161–168, Apr. 2019, doi: 10.1016/j.neunet.2019.09.020. [29]

- K. K. Mohbey, S. Kumar, and V. Koolwal, "Advertisement Prediction in Social Media Environment Using Big Data Framework," *Intelligent Systems Reference Library*, vol. 163, pp. 323–341, 2020, doi: 10.1007/978-981-13-8759-3_12. [30]
- S. Kang, C. Jeong, and K. Chung, "Tree-based real-time advertisement recommendation system in online broadcasting," *IEEE Access*, vol. 8, pp. 192693–192702, 2020, doi: 10.1109/ACCESS.2020.3031925. [31]
- R. M. Yew Liong Lim, "Descriptive and Predictive Analytics on Adventure Works Cycle: A Corporate Decision Making," *International Journal of Recent Technology and Engineering*, vol. 8, no. 6, pp. 2041–2048, Mar. 2020, doi: 10.35940/ijrte.e7007.038620. [32]
- A. Kolan, D. Moukthika, K. S. S. Sreevani, and H. Jayasree, "Click-Through Rate Prediction Using Decision Tree," *Advances in Intelligent Systems and Computing*, vol. 1090, pp. 29–37, 2020, doi: 10.1007/978-981-15-1480-7_3. [33]
- M. J. Effendi and S. A. Ali, "Click Through Rate Prediction for Contextual Advertisement Using Linear Regression," Jan. 2017, Accessed: Nov. 27, 2021. [Online]. Available: <https://arxiv.org/abs/1701.08744v1> [34]
- "Data Mining Algorithms (Analysis Services - Data Mining) | Microsoft Docs." <https://docs.microsoft.com/en-us/analysis-services/data-mining/data-mining-algorithms-analysis-services-data-mining?view=asallproducts-allversions> (accessed Sep. 07, 2021). [35]
- data mining. محاضرات الجامعة الافتراضية* [36]
- "SSIS How to Create an ETL Package - SQL Server Integration Services (SSIS) | Microsoft Docs." <https://docs.microsoft.com/en-us/sql/integration-services/ssis-how-to-create-an-etl-package?view=sql-server-ver15> (accessed Dec. 27, 2021). [37]
- "tf.keras.layers.BatchNormalization | TensorFlow Core v2.7.0." https://www.tensorflow.org/api_docs/python/tf/keras/layers/BatchNormalization (accessed Dec. 09, 2021). [38]
- "tf.keras.layers.Dropout | TensorFlow Core v2.7.0." https://www.tensorflow.org/api_docs/python/tf/keras/layers/Dropout (accessed Dec. 09, 2021). [39]
- "Adam." <https://keras.io/api/optimizers/adam/> (accessed Dec. 13, 2021). [40]
- N. K. Manaswi, *Deep Learning with Applications Using Python: Chatbots and Face, Object, and Speech Recognition With TensorFlow and Keras*. 2018. [41]
- J. Chen, B. Sun, H. Li, H. Lu, and X. S. Hua, "Deep CTR prediction in display advertising," *MM 2016 - Proceedings of the 2016 ACM Multimedia Conference*, pp. 811–820, Sep. 2016, doi: 10.1145/2964284.2964325. [42]
- K. Rama, P. Kumar, and B. Bhasker, "Deep Learning to Address Candidate Generation and Cold Start Challenges in Recommender Systems: A Research Survey," Jul. 2019, Accessed: Dec. 02, 2021. [Online]. Available: <https://arxiv.org/abs/1907.08674v1> [43]
- 19)." <https://www.who.int/ar/emergencies/diseases/novel-covid-19/question-and-answers-hub/q-a-detail/coronavirus-disease-covid-19> (accessed Dec. 27, 2021). [44]

