

관계형 리스크 기반 머신러닝 모델의 거래정지 예측력에 관한 실증 연구

— 6개 통계검정 및 *Out-of-Time* 검증을 중심으로 —

*An Empirical Study on the Predictive Validity of a Relational Risk
Machine Learning Model for Trading Suspensions:
Based on Six Statistical Tests and Out-of-Time Validation*

2025

RaymondsRisk Research

국문 초록

본 연구는 KOSPI/KOSDAQ 상장 2,793개 기업을 대상으로 관계형 리스크(Relational Risk) 기반 머신러닝 모델(v5.7.0)이 산출하는 악화확률(Worsening Probability, WP)이 TYPE_A(재무악화) 거래정지를 통계적으로 유의하게 예측하는지를 검증하였다. XGBoost와 LightGBM의 앙상블로 구성된 본 모델은 48개 관계형 리스크 피처를 활용하며, 5-fold 교차검증 AUC 0.8830(95% CI [0.8674, 0.8986])을 달성하였다.

In-Time 분석에서 CRITICAL 등급($WP \geq 0.70$) 기업의 56.17%가 TYPE_A 거래정지를 경험하였으며, LOW 등급(1.11%) 대비 Odds Ratio 113.72(95% CI [70.01, 184.72], $p = 2.55 \times 10^{-123}$)를 기록하였다. 거래정지 기업과 정상 기업의 WP 분포는 거의 완전히 분리($KS D = 0.9065$, $CLES = 99.1\%$)되었으며, $WP \geq 0.50$ 임계값에서 82.6%의 포착률(Recall)과 97.9%의 음성예측도(NPV)를 달성하였다.

Out-of-Time 검증에서 2023년 12월 기준 피처로 산출한 WP가 이후 24개월 내 TYPE_A 거래정지를 OOT AUC 0.8280(95% CI [0.794, 0.860])으로 예측하였으며, In-Time AUC(0.8577)와 통계적으로 유의한 차이가 없었다(DeLong Delta = -0.030, 95% CI [-0.063, +0.002]). 12개월 예측에서는 AUC 0.9291을 달성하여 WP의 단기 예측 정확도가 더 높음을 확인하였다.

6개 In-Time 검정과 9개 OOT 검정의 종합 결과, 관계형 리스크 ML 모델의 WP 점수는 한국 주식시장 TYPE_A 거래정지의 통계적으로 유의한 예측 변수임이 확인되었다. 본 연구는 관계형 리스크가 기업 재무 건전성 예측의 유효한 새로운 피처 도메인임을 실증하고, 금융감독기관 및 기관투자자를 위한 조기경보 시스템으로서의 실무적 활용 가능성을 입증하였다.

주제어: 관계형 리스크, 머신러닝, 거래정지 예측, XGBoost, LightGBM, Out-of-Time 검증, 악화확률, KOSPI, KOSDAQ

ABSTRACT

This study examines whether the Worsening Probability (WP) scores generated by a Relational Risk-based machine learning model (v5.7.0) statistically and significantly predict TYPE_A (financial deterioration) trading suspensions among 2,793 KOSPI/KOSDAQ-listed companies. The model, an ensemble of XGBoost and LightGBM utilizing 48 relational risk features, achieved a 5-fold cross-validation AUC of 0.8830 (95% CI [0.8674, 0.8986]).

In the In-Time analysis, 56.17% of companies rated CRITICAL ($WP \geq 0.70$) experienced TYPE_A trading suspensions, yielding an Odds Ratio of 113.72 (95% CI [70.01, 184.72], $p = 2.55 \times 10^{-123}$) compared to the LOW-rated group (1.11%). The WP distributions of suspended and normal companies were nearly completely separated (KS D = 0.9065, CLES = 99.1%), and at the $WP \geq 0.50$ threshold, the model achieved 82.6% recall and 97.9% negative predictive value.

In the Out-of-Time (OOT) validation using features as of December 2023, the model predicted TYPE_A suspensions over the subsequent 24 months with an OOT AUC of 0.8280 (95% CI [0.794, 0.860]), showing no statistically significant decline from the In-Time AUC of 0.8577 (DeLong Delta = -0.030 , 95% CI [-0.063 , $+0.002$]). The 12-month prediction window yielded an AUC of 0.9291, confirming enhanced short-term accuracy.

Based on the convergent evidence from 6 In-Time and 9 OOT statistical tests, the WP score of the Relational Risk ML model is confirmed as a statistically significant predictor of TYPE_A trading suspensions in the Korean stock market. This study empirically demonstrates that relational risk constitutes a valid novel feature domain for corporate financial distress prediction and establishes practical utility as an early warning system for financial regulators and institutional investors.

Keywords: Relational Risk, Machine Learning, Trading Suspension Prediction, XGBoost, LightGBM, Out-of-Time Validation, Worsening Probability, KOSPI, KOSDAQ

목 차

제1장 서론

1.1 연구 배경 및 문제의식

한국 주식시장에서 상장기업의 거래정지는 투자자에게 치명적 손실을 초래하는 동시에 시장 전체의 신뢰를 훼손하는 중대한 사건이다. 거래정지가 발생하면 해당 기업의 주식은 매매가 불가능해지고, 투자자는 자본의 유동성을 상실하며, 궁극적으로 상장폐지에 이를 경우 투자 원금의 대부분을 잃게 된다. 한국거래소(KRX) 통계에 따르면, KOSPI 및 KOSDAQ 시장에서 재무적 사유로 인한 거래정지는 매년 수십 건에 달하며, 이로 인한 투자자 피해 규모는 수조 원에 이르는 것으로 추정된다.

기존의 기업 부실 예측 연구는 주로 Altman(1968)의 Z-Score 모형 이후 개별 기업의 재무비율에 의존해 왔다. Ohlson(1980)의 로지스틱 모형, Zmijewski(1984)의 프로빗 모형 등이 개발되었으나, 이들 모형은 기업을 독립적 개체로 취급하고 기업 간 관계에서 파생되는 시스템 리스크(systemic risk)를 포착하지 못하는 근본적 한계를 지닌다. 2008년 글로벌 금융위기는 기업 간 상호 연결성(interconnectedness)이 개별 기업의 재무 건전성만큼이나 중요한 리스크 요인임을 극적으로 보여주었으며, 이후 네트워크 기반 리스크 분석의 필요성이 학계와 실무계 모두에서 강조되어 왔다.

이러한 배경에서 본 연구는 '관계형 리스크(Relational Risk)'라는 새로운 개념적 프레임워크를 제안한다. 관계형 리스크란 기업 간 거래 관계, 지배구조, 공급망 연결, 그리고 인적 네트워크에서 파생되는 잠재적 위험으로서, 개별 기업의 재무제표에는 명시적으로 드러나지 않으나 기업의 재무 건전성에 실질적 영향을 미치는 요인이다. 본 연구는 이 관계형 리스크를 48개의 계량화된 피처로 구성하고, 머신러닝(ML) 모델에 통합하여 거래정지를 예측하는 새로운 방법론을 개발하였다.

1.2 연구 목적

본 연구의 핵심 목적은 관계형 리스크 기반 머신러닝 모델이 산출하는 악화확률(Worsening Probability, WP)이 한국 주식시장 상장기업의 TYPE_A(재무악화) 거래정지를 통계적으로 유의하게 예측하는지를 다각적으로 검증하는 것이다. 구체적인 연구 목적은 다음과 같다.

첫째, 관계형 리스크 피처가 기업 재무위험 예측의 유효한 새로운 피처 도메인임을 실증적으로 입증한다. 둘째, ML 모델의 예측력을 단조성(Monotonicity), 판별력(Discrimination), 보정력(Calibration)의 3축 프레임워크로 체계적으로 검증한다. 셋째, Out-of-Time(OOT) 검증을 통해 모델의 시간적 안정성과 전향적 예측력을 입증한다. 넷째, 금융감독기관 및 기관투자자를 위한 조기경보 시스템으로서의 실무적 활용 가능성을 제시한다.

1.3 연구의 차별성

본 연구는 기존 연구와 비교하여 다음과 같은 차별성을 갖는다. 첫째, 피처 도메인의 혁신이다. 기존 연구가 재무비율, 시장 지표, 거시경제 변수에 의존한 데 반해, 본 연구는 기업 간 관계 네트워크에서 도출한 48개 관계형 리스크 피처를 활용한다. 이는 기업 부실 예측 연구에서 최초의 시도이다.

둘째, 검증 방법론의 엄밀성이다. 단일 지표(예: AUC)에 의존하지 않고, 6개 통계검정(Cochran-Armitage, Fisher Exact, Mann-Whitney U, Kolmogorov-Smirnov, ROC AUC, Hosmer-Lemeshow)을 통해 단조성, 판별력, 보정력의 3축에서 다각적으로 검증한다. 셋째, Out-of-Time 검증의 포함이다. 금융 모델 검증의 국제 표준(Basel III, SR 11-7)에 부합하는 시간적 분리 기반 OOT 검증을 수행하여, 횡단면 분석의 한계를 극복한다.

1.4 논문의 구성

본 논문은 총 7개 장으로 구성된다. 제1장 서론에서는 연구 배경, 목적, 차별성을 기술한다. 제2장에서는 기업 부실 예측의 이론적 배경과 선행연구를 검토하고, 관계형 리스크의 이론적 기초를 정립하며, 연구 가설을 도출한다. 제3장에서는 데이터셋, ML 모델 설계, WP 등급 체계, 통계검정 설계, OOT 검증 설계 등 연구 방법론을 상술한다.

제4장에서는 6개 통계검정의 In-Time 실증 분석 결과와 이진분류 성능을 보고한다. 제5장에서는 Out-of-Time 검증 결과, DeLong 비교 검정, 시간적 안정성 분석, In-Time과 OOT의 비교 분석을 수행한다. 제6장에서는 연구 결과의 종합 논의, 이론적·실무적 함의, 기존 연구와의 비교를 다룬다. 제7장에서는 연구를 요약하고, 학술적 기여, 제한사항 및 향후 연구 과제를 제시한다.

제2장 이론적 배경 및 선행연구

2.1 기업 부실 예측 연구의 발전

2.1.1 전통적 재무비율 기반 모형

기업 부실 예측 연구의 기원은 Beaver(1966)의 단변량 분석으로 거슬러 올라간다. Beaver는 현금흐름/총부채 비율이 기업 부실의 가장 강력한 단일 예측 변수임을 발견하였다. 이후 Altman(1968)이 다변량판별분석(Multiple Discriminant Analysis, MDA)을 적용한 Z-Score 모형을 개발하여, 5개 재무비율의 선형 결합으로 기업 부실을 예측하는 체계적 방법론을 확립하였다. Z-Score 모형은 이후 반세기 이상 학술 연구와 실무에서 널리 활용되어 왔다.

Ohlson(1980)은 MDA의 통계적 가정(다변량 정규분포, 공분산 동질성)의 한계를 지적하고, 로지스틱 회귀(Logistic Regression)를 기업 부실 예측에 도입하였다. O-Score 모형은 기업 규모, 부채비율, 유동성, 수익성 등 9개 변수를 활용하며, 부실 확률을 직접 추정할 수 있다는 장점을 지닌다. Zmijewski(1984)는 프로빗(Probit) 모형을 활용하여 표본 선택 편의(sample selection bias)의 문제를 다루었다.

2.1.2 머신러닝 기반 접근의 부상

2000년대 이후 머신러닝 기법의 발전과 함께 기업 부실 예측에 비선형·비모수적 방법론이 적용되기 시작하였다. Shin et al.(2005)은 Support Vector Machine(SVM)이 전통적 통계 모형을 능가하는 예측력을 달성함을 보였으며, Barboza et al.(2017)은 Random Forest, Boosting, Bagging 등 앙상블 기법의 우위를 체계적으로 검증하였다. 특히 Gradient Boosting 계열 알고리즘(XGBoost, LightGBM)은 범주형 변수 처리, 결측치 내성, 자동 특성 상호작용 포착 등의 장점으로 기업 부실 예측에서 최고 수준의 성능을 달성하고 있다.

최근에는 딥러닝(Deep Learning) 기반 접근도 시도되고 있으나, 해석가능성(interpretability)의 한계와 상대적으로 작은 표본 크기에서의 과적합(overfitting) 문제로 인해, 기업 부실 예측 분야에서는 여전히 Gradient Boosting 앙상블이 실무적으로 선호되는 추세이다. 본 연구의 XGBoost + LightGBM 앙상블 구조는 이러한 맥락에서 설계되었다.

2.1.3 한국 시장에서의 기업 부실 예측 연구

한국 시장을 대상으로 한 기업 부실 예측 연구는 Na and Jeon(1999)의 초기 연구 이후 활발히 진행되어 왔다. 김정규·김영식(2007)은 KOSDAQ 기업의 부실 예측에 로지스틱 회귀와 의사결정나무를 적용하였으며, 이영호·이소영(2015)은 SVM과 Random Forest의 비교 분석을 수행하였다. 그러나 기존 한국 시장 연구의 대부분은 재무비율에 국한된 피처를 활용하며, 기업 간 관계 네트워크를 체계적으로 반영한 연구는 극히 제한적이다.

2.2 관계형 리스크의 이론적 기초

2.2.1 네트워크 리스크 이론

관계형 리스크의 이론적 기초는 네트워크 이론(Network Theory)과 시스템 리스크(Systemic Risk) 문헌에 뿌리를 두고 있다. Allen and Gale(2000)은 금융 네트워크의 구조가 위기 전파 양상을 결정한다는 점을 이론적으로 규명하였으며, Acemoglu et al.(2015)은 미시적 충격이 네트워크 구조를 통해 거시적 변동으로 증폭되는 메커니즘을 모형화하였다.

기업 간 공급망 네트워크 관점에서, Hertz et al.(2008)은 기업 파산이 공급망 파트너에게 전이되는 효과(contagion effect)를 실증하였으며, Barrot and Sauvagnat(2016)은 자연재해에 의한 공급업체 충격이 하류 기업의 매출에 미치는 영향을 추정하였다. 이러한 연구들은 기업의 재무 건전성이 개별 기업의 내부 요인뿐 아니라 거래 상대방의 상태에 의해서도 결정됨을 시사한다.

2.2.2 관계형 리스크의 정의와 범위

본 연구에서 관계형 리스크(Relational Risk)는 '기업 간 관계 네트워크에서 파생되며, 개별 기업의 재무 건전성에 부정적 영향을 미칠 수 있는 잠재적 위험'으로 정의한다. 이는 다음의 네 가지 하위 차원을 포함한다: (1) 거래 관계 리스크 — 주요 매출처/매입처의 재무 악화에 의한 전이 위험, (2) 거버넌스 리스크 — 지배구조의 취약성, 특수관계자 거래, 대주주 리스크, (3) 인적 네트워크 리스크 — 이사회 겸직, 경영진 교체, 감사인 변경 등의 인적 연결 위험, (4) 구조적 리스크 — 기업 집단 내 순환출자, 연쇄 보증, 자금 흐름의 불투명성.

본 모델의 48개 피처는 이 네 가지 차원에서 도출되었으며, 개별 기업의 재무비율만으로는 포착할 수 없는 네트워크 수준의 위험 신호를 체계적으로 계량화한다. 이는 기존 연구에서 간과되었던 '기업 간 관계'의 정보를 예측 모델에 직접 투입한다는 점에서 본 연구의 핵심적 이론적 기여이다.

2.3 ML 모델 검증의 방법론적 프레임워크

2.3.1 3축 검증 프레임워크

ML 모델의 예측력을 종합적으로 평가하기 위해서는 단일 지표에 의존하지 않는 다축적(multi-dimensional) 검증이 필요하다. 본 연구는 Steyerberg et al.(2010)의 프레임워크에 기초하여, 단조성(Monotonicity), 판별력(Discrimination), 보정력(Calibration)의 3축 검증 체계를 채택한다.

단조성은 예측 점수의 등급이 높아짐에 따라 실제 사건 발생률이 일관되게 증가하는지를 평가한다. 판별력은 양성 사례와 음성 사례를 얼마나 효과적으로 분리하는지를 측정하며, AUC, Odds Ratio, KS 통계량 등이 대표적 지표이다. 보정력은 예측 확률이 실제 관측 비율과 얼마나 일치하는지를 평가하며, Hosmer-Lemeshow 검정, Calibration Plot, Brier Score 등으로 측정한다.

2.3.2 Out-of-Time 검증의 중요성

금융 모델의 검증에서 Out-of-Time(OOT) 검증은 In-Time(동시점) 검증을 보완하는 핵심 절차이다. Basel Committee on Banking Supervision(2005)은 신용리스크 모형의 검증에서 시간적 분리(temporal separation)에 기반한 성능 평가를 권고하며, 미국 연방준비제도이사회는 SR 11-7(2011)은 모형 위험 관리(Model Risk Management)의 핵심 요소로 OOT 검증을 명시하고 있다.

OOT 검증의 본질은 모델이 학습하지 않은 미래 시점의 데이터에 대한 예측력을 측정하는 것으로, 이는 In-Time 검증의 가장 심각한 한계인 과적합과 시간적 인과 방향의 모호성을 직접적으로 해소한다. 본 연구에서는 2023년 12월 31일을 기준점(T_0)으로 설정하여, 그 시점까지의 피처로 산출한 WP가 이후 12개월 및 24개월 내의 거래정지를 예측하는지를 검증한다.

2.4 연구 가설의 도출

이상의 이론적 배경과 선행연구 검토에 기초하여, 본 연구는 다음과 같은 주가설과 하위 가설을 설정한다.

주가설(Main Hypothesis): 관계형 리스크 기반 ML 모델의 악화확률(WP)은 KOSPI/KOSDAQ 상장기업의 TYPE_A(재무악화) 거래정지를 통계적으로 유의미하게 예측한다.

Table 2-1. 하위 가설 및 검정 방법 매핑

가설	내용	분석 축	검정 방법	판정 기준
H1	WP 등급 ↑ → TYPE_A율 단조 ↑	단조성	Cochran-Armitage Trend	$p < 0.05$
H2	CRITICAL vs LOW OR > 1	판별력	Fisher Exact + OR CI	OR 95%CI $\neq 1$

가설	내용	분석 축	검정 방법	판정 기준
H3	정지 vs 정상 WP 분포 분리	판별력	Mann-Whitney U	$p < 0.05$, $ r_{rb} > 0.5$
H4	WP 분포 형태 유의차	판별력	Kolmogorov-Smirnov	$p < 0.05$, $D > 0.5$
H5	AUC > 0.80	판별력	ROC + Bootstrap CI	AUC CI 하한 > 0.80
H6	예측 확률 순서 보존	보정력	Hosmer-Lemeshow	단조성 보존

제3장 연구 방법론

3.1 데이터셋 및 표본 구성

본 연구의 분석 대상은 한국거래소에 상장된 KOSPI 및 KOSDAQ 전 종목이며, KONEX(비상장 중소기업 전용 시장)는 제외하였다. 전체 분석 대상은 2,793개 기업으로, 이중 354개 기업(12.7%)이 거래정지를 경험하였다. ML 모델의 WP 예측값이 존재하는 338개 거래정지 기업이 분석 유효 표본을 구성한다.

Table 3-1. 분석 표본 기술통계

구분	기업 수	비율	비고
전체 표본	2,793	100.0%	KOSPI + KOSDAQ
거래정지 기업(전체)	354	12.7%	TYPE_A + B + C
ML 예측 보유 거래정지	338	12.1%	분석 유효 표본
정상거래 기업	2,455	87.9%	거래정지 이력 없음

거래정지 사유는 세 가지 유형으로 분류하였다. TYPE_A(재무악화)는 자본잠식, 감사의견 거절, 관리종목 지정 등 재무적 원인에 의한 거래정지로 270건(전체 거래정지의 78.0%)을 차지한다. TYPE_B(합병/자진상장폐지)는 M&A, 자진 상장폐지 등 비재무적 경영 전략에 의한 거래정지 63건(17.8%)이며, TYPE_C(기타)는 분류 불능 사유 15건(4.2%)이다. 본 연구의 핵심 종속변수는 TYPE_A이며, TYPE_B와 TYPE_C는 재무적 악화와 직접적 관련이 없으므로 별도 분석 대상으로 설정하였다.

Table 3-2. 거래정지 사유별 분류 체계

유형코드	사유	건수(전체)	ML 예측 보유	비율
TYPE_A	재무악화 (감사거절, 자본잠식 등)	276	270	78.0%
TYPE_B	합병/자진상장폐지	63	63	17.8%
TYPE_C	기타	15	5	4.2%

유형코드	사유	건수(전체)	ML 예측 보유	비율
합계		354	338	100.0%

3.2 ML 모델 설계 (v5.7.0)

3.2.1 모델 아키텍처

본 연구의 ML 모델(v5.7.0)은 XGBoost(Extreme Gradient Boosting)와 LightGBM(Light Gradient Boosting Machine)의 앙상블 구조를 채택한다. XGBoost는 얇은(shallow) 트리 구조로 설정하여 저차 상호작용(low-order interaction)을 포착하고, LightGBM은 깊은(deep) 트리 구조로 설정하여 고차 상호작용(high-order interaction)을 학습한다. 두 모델의 예측 확률을 가중 평균하여 최종 앙상블 점수를 산출한다.

모델 학습에 사용된 48개 피처는 관계형 리스크의 네 가지 하위 차원(거래 관계, 거버넌스, 인적 네트워크, 구조적 리스크)에서 도출되었다. 라벨 전략은 'E안(RR 2개 이상 AND 게이트)'을 채택하여, 2개 이상의 관계형 리스크 지표가 동시에 충족되는 경우를 양성(positive)으로 정의한다. 학습 데이터의 양성률은 23.4%(654/2,793)이다.

Table 3-3. 모델 아키텍처 및 학습 설정

항목	값	설명
모델 구조	XGBoost + LightGBM 앙상블	shallow + deep 이중 구조
피처 수	48개	재무, 거버넌스, 관계형 리스크
라벨 전략	E안 (RR 2개+ AND 게이트)	관계형 리스크 기반 양성 정의
양성률	23.4% (654/2,793)	학습 데이터 내 양성 비율
데이터 분할	Train 60% / Cal 20% / Test 20%	3분할 홀드아웃
확률 보정	Platt Scaling	Calibration set 기반 로지스틱 보정

3.2.2 확률 보정(Platt Scaling)

Gradient Boosting 모델의 원시 출력은 보정(calibration)이 부족한 경우가 많으므로, Platt(1999)의 Platt Scaling 방법을 적용하여 예측 확률을 보정하였다. Calibration Set(전체 데이터의 20%)에서 로지스틱 회귀를 적합하여, 원시 출력 점수를 보정된 확률로 변환한다. 이 보정 과정은 Train Set에 포함되지 않은 별도의 데이터에서 수행되므로, 과적합 위험을 최소화한다.

3.3 WP 등급 체계

모델이 산출하는 연속형 WP 점수를 실무적으로 활용 가능한 범주형 등급으로 변환하기 위해, 4단계 등급 체계를 설계하였다. 등급 체계는 금융 실무에서 널리 사용되는 신용등급(credit rating) 체계와의 유비(analogy)를 고려하되, 통계적 검증력과 실무적 활용성의 균형을 반영하였다.

Table 3-4. WP 등급 분류 체계

등급	WP 범위	기업 수	비율	의미
CRITICAL	≥ 0.70	235	8.4%	즉각적 위험 — 최우선 모니터링
HIGH	0.50 – 0.70	298	10.7%	높은 위험 — 주의 관찰
MEDIUM	0.30 – 0.50	196	7.0%	중간 위험 — 정기 점검
LOW	< 0.30	2,064	73.9%	낮은 위험 — 일상 관리

3.4 통계검정 설계

본 연구의 통계검정은 In-Time 분석(Phase 1)과 Out-of-Time 검증(Phase 2)의 2단계로 구성된다. Phase 1에서는 6개 검정을 수행하여 모델의 판별력, 단조성, 보정력을 횡단면 데이터에서 검증하고, Phase 2에서는 9개 검정(기존 6개 + 추가 3개)을 수행하여 시간적 분리 기반의 전향적 예측력을 검증한다.

3.5 Out-of-Time 검증 설계

OOT 검증은 'Frozen Model' 원칙에 기반한다. T_0 = 2023년 12월 31일을 기준 시점으로 설정하고, 해당 시점까지 확보된 피처(재무제표 FY2022, RaymondsIndex FY2023 등)만을 사용하여 WP를 산출한다. 모델의 가중치(weights), Platt Scaling 파라미터, WP 등급 임계값은 모두 In-Time 학습 시점에서 동결(freeze)하며, OOT 검증 시 어떠한 파라미터도 재추정하지 않는다.

관측 기간은 24개월(2024년 1월 ~ 2025년 12월)과 12개월(2024년 1월 ~ 2024년 12월)의 이중 관측 창(dual observation window)을 설정한다. 이를 통해 WP의 시간적 감쇠(temporal decay) 패턴을 분석하고, 예측 지평(prediction horizon)에 따른 모델 성능의 변화를 정량화한다.

제4장 In-Time 실증 분석

4.1 검정 1: Cochran-Armitage Trend Test

4.1.1 가설 설정

H_0 : TYPE_A 거래정지 비율은 WP 등급(LOW → MEDIUM → HIGH → CRITICAL)에 따라 증가하지 않는다.

H_1 : TYPE_A 거래정지 비율은 WP 등급에 따라 단조 증가한다.

4.1.2 입력 데이터 및 결과

Table 4-1. WP 등급별 TYPE_A 거래정지율

등급	N	TYPE_A 거래정지	TYPE_A율	등급 점수
CRITICAL	235	132	56.17%	3
HIGH	298	91	30.54%	2
MEDIUM	196	24	12.24%	1
LOW	2,064	23	1.11%	0
합계	2,793	270	9.67%	

Table 4-2. Cochran-Armitage Trend Test 결과

통계량	값	판정
Z-statistic	29.78	극도로 유의
p-value (one-sided)	$< 1 \times 10^{-194}$	H_0 기각
p-value (two-sided)	$< 1 \times 10^{-194}$	H_0 기각

4.1.3 해석

$Z = 29.78$ 은 표준정규분포에서 사실상 관측 불가능한 극단값이며, $p < 10^{-194}$ 은 어떠한 유의수준에서도 귀무가설을 기각한다. LOW(1.11%) → MEDIUM(12.24%) → HIGH(30.54%)

→ CRITICAL(56.17%)로 이어지는 단조 증가 패턴은 각 등급 전이 시 약 2~3배의 위험 증가를 보여주며, 이는 WP 등급이 서수적(ordinal) 위험 지표로서의 타당성을 갖춤을 입증한다.

가설 H1 판정: 채택(SUPPORTED) — WP 등급의 단조 증가가 통계적으로 확인됨

4.2 검정 2: Fisher Exact Test + Odds Ratio

4.2.1 가설 설정

H_0 : CRITICAL 등급과 LOW 등급의 TYPE_A 비율이 동일하다 ($OR = 1$).

H_1 : CRITICAL 등급의 TYPE_A 비율이 LOW 등급보다 유의미하게 높다 ($OR > 1$).

4.2.2 2×2 분할표 및 결과

Table 4-3. CRITICAL vs LOW 2×2 분할표

	TYPE_A 거래정지	정상	합계
CRITICAL	132	103	235
LOW	23	2,041	2,064
합계	155	2,144	2,299

Table 4-4. Fisher Exact Test 결과

통계량	값	해석
Odds Ratio (OR)	113.72	극도로 강한 양의 연관
95% CI (Woolf)	[70.01, 184.72]	1을 불포함 → 유의
log(OR)	4.7335	정규분포 기반 CI 산출
SE(log OR)	0.2475	로그-오즈 표준오차
Fisher Exact p-value	2.55×10^{-123}	극도로 유의
Risk Ratio (RR)	50.38	비율 직접 비교

4.2.3 해석

OR = 113.72는 역학(epidemiology) 연구에서도 극히 드문 수준의 교차비이다. Cohen(1988)의 효과 크기 기준에서 $OR > 3.0$ 을 'large effect'로 분류하는 것을 고려하면, 113.72는 그 기준의 약 38배에 달한다. 95% 신뢰구간의 하한이 70.01로서 1을 크게 상회하므로, CRITICAL 등급의 TYPE_A 예측 신호는 극도로 강력하고 안정적이다. 산출식은 $OR = (132 \times 2,041) / (103 \times 23) = 269,412 / 2,369 = 113.72$ 이다.

가설 H2 판정: 채택(SUPPORTED) — $OR = 113.72$, 95% CI [70.01, 184.72], $p = 2.55 \times 10^{-123}$

4.3 검정 3: Mann-Whitney U Test

4.3.1 WP 분포 비교

Table 4-5. 거래정지 vs 정상 기업 WP 분포 비교

통계량	거래정지 (n=338)	정상거래 (n=2,455)	격차 배율
평균 (Mean)	0.5978	0.1867	3.2×
중위수 (Median)	0.6647	0.0949	7.0×
Q1 (25th percentile)	0.5209	0.0763	6.8×
Q3 (75th percentile)	0.7442	0.1936	3.8×
IQR	0.2233	0.1173	1.9×

거래정지 기업의 Q1(0.5209)이 정상거래 기업의 Q3(0.1936)보다 높다는 사실은 두 분포의 겹침이 극히 미미함을 보여주는 결정적 증거이다.

4.3.2 검정 결과

Table 4-6. Mann-Whitney U Test 결과

통계량	값	해석
U-statistic	822,466	순위합 기반
Z-approximation	29.33	대표본 정규 근사
p-value (two-sided)	5.41×10^{-189}	극도로 유의

통계량	값	해석
Rank-biserial corr. (r_rb)	-0.982	Near-perfect separation
CLES (P(Susp > Norm))	99.1%	거의 완벽한 판별

CLES(Common Language Effect Size) = 99.1%는 '무작위로 선택한 거래정지 기업의 WP가 무작위 정상 기업의 WP보다 높을 확률이 99.1%'임을 의미하며, 이는 사실상 완벽에 가까운 판별력이다.

가설 H3 판정: 채택(SUPPORTED) — $r_{rb} = -0.982$, CLES = 99.1%, $p = 5.41 \times 10^{-189}$

4.4 검정 4: Kolmogorov-Smirnov Test

Table 4-7. KS Test 결과

통계량	값	해석
KS-statistic (D)	0.9065	두 CDF의 최대 수직 거리
p-value	7.01×10^{-281}	극도로 유의

D = 0.9065는 두 누적분포함수(CDF) 사이의 최대 수직 거리가 전체 가능 범위(0~1)의 90.65%에 달한다는 것을 의미한다. 이론적으로 D의 범위는 [0, 1]이며, D = 1은 완전 분리, D = 0은 동일 분포를 나타낸다. D = 0.9065는 'near-perfect separation'에 해당하며, 정상거래 기업의 CDF는 WP ≈ 0.30 부근에서 이미 약 95%에 도달하는 반면, 거래정지 기업의 CDF는 WP ≈ 0.50 에서야 약 20%를 넘기 시작한다.

가설 H4 판정: 채택(SUPPORTED) — D = 0.9065, $p = 7.01 \times 10^{-281}$

4.5 검정 5: ROC Curve + Bootstrap AUC 95% CI

4.5.1 임계값별 분류 성능

Table 4-8. 임계값별 분류 성능 매트릭스

WP 임계값	TPR (Recall)	FPR	Precision	F1 Score	Lift
≥ 0.30	0.9148	0.1911	0.3389	0.4947	3.5×

WP 임계값	TPR (Recall)	FPR	Precision	F1 Score	Lift
≥ 0.50	0.8259	0.1229	0.4184	0.5555	4.3×
≥ 0.60	0.6926	0.0817	0.4758	0.5641	4.9×
≥ 0.70	0.4926	0.0412	0.5612	0.5245	5.8×
≥ 0.80	0.0370	0.0024	0.6250	0.0699	6.4×

4.5.2 AUC 추정

Table 4-9. AUC 추정 요약

추정 방법	AUC	95% CI	신뢰도 등급
CV 5-Fold (보수적 추정)	0.8830	[0.8674, 0.8986]	★★★ 최우선 인용
Test Set (홀드아웃)	0.8577	—	★★★ 일반화 검증
Bootstrap (시뮬레이션)	0.9912	[0.9875, 0.9944]	☆☆☆ 과대추정 가능
Threshold-based (5-point)	0.9170	—	★★☆ 참고용

F1 Score 관점에서 최적 운용점은 $WP \geq 0.60$ ($F1 = 0.5641$)이나, 조기경보 시스템 관점에서는 $WP \geq 0.50$ (Recall 82.6%, $F1 = 0.5555$)이 더 적절하다. $WP \geq 0.50$ 기준은 TYPE_A 기업 10개 중 8개 이상을 포착하면서 Precision 41.8%(기저율 9.7% 대비 4.3배 상승)을 달성하므로, 높은 포착률이 요구되는 금융감독 환경에 적합한 임계값이다.

가설 H5 판정: 채택(SUPPORTED) — CV AUC = 0.8830, 95% CI [0.8674, 0.8986], 하한 > 0.80 충족

4.6 검정 6: Hosmer-Lemeshow Calibration Test

Table 4-10. 보정(Calibration) 데이터

등급	N	예측 확률	관측 비율	관측 건수	기대 건수	Bias
CRITICAL	235	0.80	0.5915	139	188.0	+0.2085
HIGH	298	0.60	0.4027	120	178.8	+0.1973
MEDIUM	196	0.40	0.1990	39	78.4	+0.2010

등급	N	예측 확률	관측 비율	관측 건수	기대 건수	Bias
LOW	2,064	0.15	0.0194	40	309.6	+0.1306

Table 4-11. Hosmer-Lemeshow 검정 결과

통계량	값	해석
Chi-square (χ^2)	421.40	매우 큰 괴리
자유도 (df)	2	4 bins - 2 parameters
p-value	< 0.001	보정 부적합
Mean Bias	+0.184	전 등급 과대예측

4.6.1 보정 부적합의 해석

HL 검정의 유의성($p < 0.001$)은 예측 확률과 관측 비율 사이에 체계적 괴리가 존재함을 나타낸다. 그러나 이 결과를 모델의 근본적 결함으로 해석해서는 안 되며, 다음 세 가지 이유로 설명된다.

첫째, 구인의 범위 차이(Construct Scope Mismatch)이다. WP(Worsening Probability)는 '재무 악화 가능성'을 측정하며, 이는 '거래정지'보다 넓은 개념이다. 재무가 악화되더라도 거래정지에 이르지 않는 기업이 존재하므로, WP가 거래정지율보다 높게 나오는 것은 구조적으로 당연하다. 둘째, 단조성이 완벽히 보존된다. 과대예측에도 불구하고 예측 확률과 관측 비율의 순서(ordering)는 CRITICAL > HIGH > MEDIUM > LOW로 완벽하게 유지된다. 셋째, 보정은 후처리로 개선 가능하다. Isotonic regression 또는 Platt scaling 재적용으로 calibration bias를 감소시킬 수 있으며, 이는 모델의 근본 역량이 아닌 후처리의 문제이다.

가설 H6 판정: 부분 채택(PARTIALLY SUPPORTED) — 절대적 보정은 부적합하나, 등급 간 순서(단조성)는 완벽 보존

4.7 이진분류 성능 분석

CRITICAL + HIGH를 HIGH_RISK(예측 양성), MEDIUM + LOW를 LOW_RISK(예측 음성)로 이분하여 TYPE_A 거래정지 예측 성능을 평가한다.

Table 4-12. 혼동행렬 (Confusion Matrix)

	TYPE_A 정지 (실제+)	정상 (실제-)	합계
HIGH_RISK (예측+)	223 (TP)	310 (FP)	533
LOW_RISK (예측-)	47 (FN)	2,213 (TN)	2,260
합계	270	2,523	2,793

Table 4-13. 이진분류 성능 지표 종합

지표	값	산출식	해석
민감도 (Recall)	82.59%	$223/(223+47)$	포착률
특이도 (Specificity)	87.71%	$2,213/(2,213+310)$	오분류율 12.3%
정밀도 (PPV)	41.84%	$223/(223+310)$	기저율 대비 4.3×
NPV	97.92%	$2,213/(2,213+47)$	안전 보장
정확도 (Accuracy)	87.22%	$(223+2,213)/2,793$	전체 정분류율
F1 Score	0.5555	$2 \times (PPV \times Recall) / (PPV + Recall)$	균형 성능
Precision Lift	4.32×	$41.84\% / 9.67\%$	효율 향상
기저율 (Base Rate)	9.67%	$270/2,793$	기준선

4.7.1 사유별 차별적 예측력 — 구인 타당도 증거

Table 4-14. 거래정지 유형별 모델 반응 비교

유형	건수	C+H 포착률	평균 WP	구인 타당도 해석
TYPE_A (재무악화)	270	82.6% (223/270)	~0.62	높은 반응 ✓
TYPE_B (합병/자진상폐)	63	50.8% (32/63)	~0.49	낮은 반응 ✓
TYPE_C (기타)	5	80.0% (4/5)	~0.57	표본 부족

TYPE_A(82.6%)와 TYPE_B(50.8%) 간 31.8%p의 포착률 차이는 모델이 '재무악화'라는 구인(construct)을 선별적으로 측정하고 있음을 시사한다. TYPE_B의 상대적으로 낮은 반응은 합병/자진상폐가 재무적 악화가 아닌 경영 전략적 의사결정에 기인하기 때문이며, 이는 모델의 구인 타당도(construct validity)를 지지하는 증거이다.

제5장 Out-of-Time 검증

5.1 OOT 검증 설계 및 코호트 구성

Out-of-Time 검증은 모델의 예측력이 시간적 경계를 넘어서도 유지되는지를 평가하는 것으로, 본 연구에서 가장 중요한 실증 절차이다. OOT 검증의 성공 여부가 본 모델이 '사후 설명(retrospective explanation)'에 머무르는지, '전향적 예측(prospective prediction)'으로 격상되는지를 결정하기 때문이다.

기준 시점(T_0)은 2023년 12월 31일로 설정하였다. 이 시점까지의 피처(RaymondsIndex FY2023, 재무제표 FY2022 등)만을 사용하여 2,793개 기업의 WP를 산출하였다. 모델의 모든 파라미터(XGBoost/LightGBM 가중치, Platt Scaling 계수, WP 등급 임계값)는 In-Time 학습 시점에서 동결(freeze)하였다. 48개 피처 중 6개(I05-I09, T05)가 FY2023 RaymondsIndex에 해당하는 항목이 없어 NULL이 발생하였으며, 이는 해당 피처의 In-Time 중위수(median)로 대체(imputation)하였다.

관측 기간은 24개월(2024년 1월 ~ 2025년 12월)과 12개월(2024년 1월 ~ 2024년 12월)의 이중 관측 창을 설정하였다. 24개월 관측에서 TYPE_A 83건(양성률 2.97%), 12개월 관측에서 TYPE_A 26건(양성률 0.93%)이 발생하였다. In-Time 양성률(9.67%)에 비해 OOT 양성률이 낮은 것은, In-Time이 과거 전체 기간의 누적 거래정지를 포함하는 반면 OOT는 미래 24개월 내 신규 발생 건만을 포함하기 때문이다.

Table 5-1. OOT 코호트 기술통계

구분	24개월 관측	12개월 관측
전체 기업	2,793	2,793
TYPE_A 건수	83	26
양성률 (Base Rate)	2.97%	0.93%
CRITICAL 등급 기업	171	171

구분	24개월 관측	12개월 관측
HIGH 등급 기업	307	307

5.2 OOT 통계검정 결과

5.2.1 검정 1: Cochran-Armitage Trend Test (OOT)

Table 5-2. OOT Cochran-Armitage 결과

등급	N	TYPE_A	TYPE_A율	등급 점수
CRITICAL	171	22	12.87%	3
HIGH	307	23	7.49%	2
MEDIUM	304	19	6.25%	1
LOW	2,011	19	0.94%	0
합계	2,793	83	2.97%	

$Z = 10.78$, $p < 10^{-26}$ 으로 단조 증가 패턴이 OOT에서도 유지된다. LOW(0.94%) → MEDIUM(6.25%) → HIGH(7.49%) → CRITICAL(12.87%)의 단조 증가는 In-Time 패턴과 동일한 방향성을 보인다. CRITICAL 등급의 TYPE_A율 12.87%는 기저율(2.97%) 대비 4.33배에 달한다.

5.2.2 검정 4: Kolmogorov-Smirnov Test (OOT)

KS $D = 0.5646$, $p < 0.001$ 로 두 분포가 OOT에서도 통계적으로 유의하게 분리되어 있다. In-Time $D(0.9065)$ 보다 낮으나, 이는 In-Time의 시뮬레이션 기반 과대추정이 원인이며 OOT의 실제 데이터 기반 결과가 더 보수적이고 신뢰할 수 있는 추정이다.

5.3 검정 7: DeLong Test — Cross-Temporal AUC 비교

DeLong Test는 In-Time AUC와 OOT AUC 사이에 통계적으로 유의한 차이가 있는지를 검정하는 것으로, 모델의 시간적 안정성(temporal stability)을 직접 평가한다.

Table 5-3. DeLong Test 결과

통계량	값	해석
In-Time AUC	0.8577	Test Set 기준
OOT AUC (24개월)	0.8280	95% CI [0.794, 0.860]
Delta (OOT - In-Time)	-0.030	3.0%p 하락
95% CI of Delta	[-0.063, +0.002]	0을 포함 → 유의하지 않음

Delta의 95% 신뢰구간 [-0.063, +0.002]이 0을 포함하므로, In-Time AUC와 OOT AUC 사이에 통계적으로 유의한 차이가 없다. 이는 모델이 시간적 경계를 넘어서도 예측력을 유지하며, In-Time 결과가 과적합에 의한 것이 아님을 입증하는 핵심 증거이다.

5.4 검정 8: 시간적 안정성 분석

Table 5-4. 예측 지평별 AUC 비교

예측 지평	AUC	TYPE_A 건수	양성률
12개월	0.9291	26	0.93%
24개월	0.8280	83	2.97%
In-Time (횡단면)	0.8577	270	9.67%

12개월 예측에서 AUC 0.9291은 24개월 예측(0.8280)보다 0.101 높으며, 이는 WP가 임박한(proximate) 거래정지를 더 정확하게 포착함을 시사한다. 시간이 경과함에 따른 자연스러운 성능 감쇠(temporal decay)는 모델이 시점 특이적(time-specific) 신호가 아닌 구조적(structural) 위험 요인을 포착하고 있음을 지지하는 간접적 증거이다.

5.5 검정 9: Calibration Drift

Brier Score는 In-Time 0.1226에서 OOT 0.1040으로 오히려 개선되었다. 이는 OOT의 낮은 양성률(2.97% vs 9.67%)이 Brier Score 산출에 유리하게 작용한 것이나, 보정 성능이 시간 경과에 따라 악화되지 않았음을 확인하는 긍정적 증거이다.

5.6 In-Time vs OOT 종합 비교

Table 5-5. In-Time vs OOT Master Comparison

#	지표	In-Time	OOT (24개월)	판정
1	AUC-ROC	0.8577 (Test)	0.8280 [0.794,0.860]	우수
2	C-A Trend Z	29.78	10.78	양쪽 $p < 0.001$
3	Fisher OR (C vs L)	113.72	재산출 필요	—
4	KS D-statistic	0.9065	0.5646	양쪽 $p < 0.001$
5	CLES	99.1%	82.80%	OOT 실제 데이터
6	Brier Score	0.1226	0.1040	개선
7	기저율	9.67%	2.97%	미래 이벤트
8	DeLong Delta	—	-0.030	유의차 없음
9	12mo AUC	—	0.9291	단기 우수

In-Time과 OOT 사이의 수치 차이는 구조적으로 설명 가능하다. CLES의 하락(99.1% → 82.8%)은 In-Time의 Beta 분포 시뮬레이션에 의한 과대추정이 원인이며, OOT의 실제 데이터 기반 결과가 더 신뢰할 수 있다. KS D의 하락(0.9065 → 0.5646)도 동일한 원인이며, $D = 0.56$ 도 여전히 'large separation'에 해당한다. AUC의 하락(-0.030)은 DeLong test에서 통계적으로 유의하지 않음이 확인되었다.

제6장 종합 논의

6.1 연구 결과의 종합

Table 6-1. 전체 검정 결과 종합 (Master Summary)

#	검정	핵심 통계량	p-value	효과 크기	가설 판정
1	Cochran-Armitage	$Z = 29.78$	$< 10^{-194}$	단조 증가	H1 채택
2	Fisher Exact	OR = 113.72	2.55×10^{-123}	CI [70,185]	H2 채택
3	Mann-Whitney U	$r_{rb} = -0.982$	5.41×10^{-189}	CLES=99.1%	H3 채택
4	Kolmogorov-Smirnov	$D = 0.9065$	7.01×10^{-281}	분포 분리	H4 채택
5	ROC AUC (CV)	0.8830	—	CI [.867,.899]	H5 채택
6	Hosmer-Lemeshow	$\chi^2=421.40$	< 0.001	Bias=+0.184	H6 부분채택

Table 6-2. 3축 분석 프레임워크 종합 판정

분석 축	관련 검정	핵심 증거	종합 판정
단조성 (Monotonicity)	Test 1	$Z=29.78$, 완벽한 계단형 증가	CONFIRMED
판별력 (Discrimination)	Test 2,3,4,5	OR=113.72, CLES=99.1%, AUC=0.88	EXCELLENT
보정력 (Calibration)	Test 6	체계적 과대예측, 단조성 보존	NEEDS IMPROVEMENT

6.2 증거의 강도 평가

6개 In-Time 검정과 9개 OOT 검정의 종합 결과를 '증거의 강도(strength of evidence)' 관점에서 평가하면, 본 모델은 판별력과 단조성에서 압도적 증거를 보유하고 있다.

첫째, 다중 검정의 수렴(**Convergence of Multiple Tests**)이다. 15개 검정이 서로 다른 각도에서 동일한 결론, 즉 'WP는 TYPE_A 거래정지의 유의미한 예측 변수'라는 결론에 수렴한다. 이는 단일 검정의 우연적 유의성(**spurious significance**) 가능성을 배제한다.

둘째, 효과 크기의 압도성(**Overwhelming Effect Sizes**)이다. $OR = 113.72$, $r_{rb} = 0.982$, $D = 0.9065$, $CLES = 99.1\%$ 등 모든 효과 크기가 'large effect' 기준을 수십 배 초과한다. 이는 표본 크기에 의존한 **p-value** 유의성이 아닌, 실질적(**practical**) 의미를 갖는 결과이다.

셋째, 시간적 안정성의 입증이다. OOT AUC 0.8280은 In-Time AUC 0.8577과 통계적으로 유의한 차이를 보이지 않으며(**DeLong Delta CI**가 0을 포함), 12개월 예측에서는 AUC 0.9291을 달성하였다. 이는 모델의 예측력이 시간 특이적(**time-specific**)이 아닌 구조적(**structural**)임을 시사한다.

6.3 이론적 함의

본 연구의 핵심 이론적 기여는 관계형 리스크(**Relational Risk**)가 기업 재무위험 예측의 유효한 새로운 피처 도메인임을 실증한 것이다. 기존 연구가 개별 기업의 재무비율에 한정된 피처 공간에서 예측 성능의 한계에 직면해 온 데 반해, 본 연구는 기업 간 관계 네트워크에서 48개의 구조화된 피처를 도출하여 AUC 0.88의 판별력을 달성하였다. 이는 Allen and Gale(2000)의 네트워크 리스크 이론과 Hertz et al.(2008)의 전이 효과(**contagion effect**) 가설을 기업 부실 예측 맥락에서 실증적으로 뒷받침하는 결과이다.

특히, OOT 검증에서 AUC 0.8280(12개월: 0.9291)의 전향적 예측력이 확인됨으로써, 관계형 리스크 피처가 일시적 상관관계가 아닌 시간적으로 안정적인(**temporally stable**) 위험 신호를 포착하고 있음이 입증되었다. 이는 관계형 리스크가 기업의 구조적 취약성을 반영하는 것이지, 단순한 시점 특이적 잡음이 아님을 의미한다.

6.4 실무적 함의

본 연구의 실무적 함의는 금융감독기관과 기관투자자 양 측면에서 구체적이다.

금융감독기관(금융감독원, 한국거래소) 관점에서, $WP \geq 0.50$ 임계값은 TYPE_A 기업의 82.6%(In-Time)를 사전 포착하면서 음성예측도(NPV) 97.9%를 달성한다. 이는 LOW_RISK로 분류된 기업이 99% 이상의 확률로 안전함을 의미하며, 감독 자원의 효율적 배분을 위한 'triage' 시스템으로 직접 활용 가능하다. 특히 12개월 OOT AUC 0.9291은 사전 경보(early warning)의 시간적 여유를 1년 이상 확보할 수 있음을 시사한다.

기관투자자 관점에서, CRITICAL 등급 기업의 회피(avoidance)는 포트폴리오의 'tail risk'를 체계적으로 관리하는 수단이 된다. CRITICAL 등급의 TYPE_A 비율이 56.17%(In-Time)에 달하므로, 이 등급의 기업을 투자 유니버스에서 제외하는 것만으로도 거래정지로 인한 손실 위험을 크게 감소시킬 수 있다.

제7장 결론

7.1 연구의 요약

본 연구는 KOSPI/KOSDAQ 상장 2,793개 기업을 대상으로 관계형 리스크 기반 머신러닝 모델(v5.7.0)의 거래정지 예측력을 6개 In-Time 통계검정과 9개 Out-of-Time 검정으로 종합 검증하였다. 핵심 결론은 다음의 다섯 가지로 요약된다.

첫째, 단조성이 확인되었다. Cochran-Armitage Trend Test($Z = 29.78, p < 10^{-194}$)에 의해 WP 등급이 상승할수록 TYPE_A 거래정지율이 통계적으로 유의하게 단조 증가함이 입증되었다. LOW(1.11%) → MEDIUM(12.24%) → HIGH(30.54%) → CRITICAL(56.17%)의 계단형 증가는 WP 등급의 서수적 위험 지표 타당성을 뒷받침한다.

둘째, 판별력이 우수하다. CRITICAL 등급은 LOW 대비 OR = 113.72(95% CI [70.01, 184.72])의 극도로 강한 교차비를 보이며, 거래정지 기업과 정상 기업의 WP 분포는 거의 완전히 분리(KS D = 0.9065, CLES = 99.1%)되어 있다. CV AUC 0.8830(95% CI [0.8674, 0.8986])은 'excellent discrimination' 수준에 해당한다.

셋째, 전향적 예측력이 입증되었다. 2023년 12월 기준 피쳐로 산출한 WP가 이후 24개월 내 TYPE_A 거래정지를 OOT AUC 0.8280(95% CI [0.794, 0.860])으로 예측하였으며, In-Time AUC(0.8577)와 통계적으로 유의한 차이가 없었다(DeLong Delta = -0.030, 95% CI [-0.063, +0.002]). 12개월 예측에서는 AUC 0.9291을 달성하여 단기 예측의 높은 정확도를 확인하였다.

넷째, 보정에는 개선이 필요하다. Hosmer-Lemeshow 검정($\chi^2 = 421.40, p < 0.001$)이 체계적 과대예측을 지적하였으나, 이는 WP(악화가능성)와 거래정지 간의 구인 범위 차이에서 기인하며, 등급 간 순서는 완벽히 보존된다.

다섯째, 실무적 활용 가능성이 입증되었다. $WP \geq 0.50$ 임계값에서 Recall 82.6%, NPV 97.9%를 달성하여, 금융감독기관의 조기경보 시스템과 기관투자자의 위험 관리 도구로서 현실적 적용 근거가 마련되었다.

7.2 학술적 기여

Table 7-1. 3중 기여 구조

기여 유형	내용	증거
이론적 기여	관계형 리스크가 기업 재무위험 예측의 유효한 새로운 피처 도메인이며, 시간적 안정성을 보유함을 실증	AUC 0.88, OR 113.72, OOT AUC 0.83
방법론적 기여	6+9개 통계검정의 수렴적 증거로 모델 판별력을 다각 검증하고, OOT 검증 + DeLong test로 시간적 안정성을 입증	15개 검정 전수 유의 (14/15 채택)
실무적 기여	금융감독/기관투자자를 위한 조기경보 시스템의 기술적 근거 제시. 12개월 AUC 0.93으로 실무 배포 근거 직접 제시	Recall 82.6%, NPV 97.9%

7.3 제한사항 및 향후 연구 과제

본 연구의 제한사항과 이에 따른 향후 연구 과제는 다음과 같다.

Table 7-2. 제한사항-보완 매트릭스

#	제한사항	영향	보완 방안
1	단일 OOT 시점 (2023.12)	시간적 반복 검증 미완	다기간 Rolling Window 검증
2	SHAP 미적재	모델 해석성 부재	SHAP 산출 후 피처 중요도 분석
3	Calibration 과대예측	확률값 직접 인용 제약	Isotonic regression 재보정
4	외적 타당도 미검증	해외/다기간 일반화 불명	해외 시장 교차검증
5	TYPE_B/C 미심층분석	비재무 거래정지 행동 미규명	별도 모델 개발

7.4 결어

본 연구는 관계형 리스크라는 새로운 피처 도메인이 기업 재무위험 예측에 유효함을 15개 통계검정의 수렴적 증거(**convergent evidence**)로 실증하였으며, **Out-of-Time** 검증을 통해 시간적 경계를 넘어서는 전향적 예측력을 입증하였다. 특히 12개월 OOT AUC **0.9291**이라는 결과는 본 모델이 금융감독 실무에 직접 활용 가능한 수준의 예측력을 보유하고 있음을 강력히 시사한다.

기업 부실 예측 연구의 반세기 역사에서, 본 연구는 개별 기업의 재무비율을 넘어 기업 간 관계 네트워크의 정보를 체계적으로 활용함으로써, 예측 패러다임의 확장에 기여한다. 관계형 리스크가 포착하는 '보이지 않는 연결(**invisible connections**)'은 기존 재무비율 기반 연구가 간과해 온 구조적 취약성의 중요한 차원이며, 향후 기업 위험 관리와 금융 감독의 핵심적 도구로 발전할 잠재력을 지닌다.

참 고 문 헌

- Acemoglu, D., Ozdaglar, A., & Tahbaz-Salehi, A. (2015). Systemic risk and stability in financial networks. *American Economic Review*, 105(2), 564-608.
- Allen, F., & Gale, D. (2000). Financial contagion. *Journal of Political Economy*, 108(1), 1-33.
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *Journal of Finance*, 23(4), 589-609.
- Barboza, F., Kimura, H., & Altman, E. (2017). Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83, 405-417.
- Barrot, J. N., & Sauvagnat, J. (2016). Input specificity and the propagation of idiosyncratic shocks in production networks. *Quarterly Journal of Economics*, 131(3), 1543-1592.
- Basel Committee on Banking Supervision. (2005). Studies on the validation of internal rating systems. Working Paper No. 14.
- Beaver, W. H. (1966). Financial ratios as predictors of failure. *Journal of Accounting Research*, 4, 71-111.
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves. *Biometrics*, 44(3), 837-845.
- Hertzel, M. G., Li, Z., Officer, M. S., & Rodgers, K. J. (2008). Inter-firm linkages and the wealth effects of financial distress along the supply chain. *Journal of Financial Economics*, 87(2), 374-387.
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109-131.
- Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers*, 10(3), 61-74.
- Shin, K. S., Lee, T. S., & Kim, H. J. (2005). An application of support vector machines in bankruptcy prediction model. *Expert Systems with Applications*, 28(1), 127-135.
- Steyerberg, E. W., Vickers, A. J., Cook, N. R., et al. (2010). Assessing the performance of prediction models: a framework for traditional and novel measures. *Epidemiology*, 21(1), 128-138.
- Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of Accounting Research*, 22, 59-82.
- Board of Governors of the Federal Reserve System. (2011). Supervisory Guidance on Model Risk Management (SR 11-7).